

AI 기반 민원 서비스 혁신 시나리오 및 개발 방법 공모전

Track 2 공식 제안서

AI-SPOC

AI 기반 전자민원 단일창구 서비스

지능형 관할 예측·복합 민원 분해·자동 라우팅 통합 플랫폼

기술 아키텍처 설계 중심 제안

이름: 김진웅

소속: 연세대학교 신촌캠퍼스

이메일: jinung344@gmail.com

요약. Executive Summary

AI 기반 전자민원 단일창구 서비스(AI-SPOC: AI-powered Single Point of Contact)는 현행 전자민원 행정 체계의 구조적 결함을 해소하기 위해 설계된 지능형 민원 처리 혁신 시스템이다. 본 제안서는 공모전 Track 2의 기술·설계 중심 요건에 따라, 실제 프로토타입 개발 결과물과 실측 데이터를 기반으로 AI-SPOC의 기술 아키텍처, 서비스 시나리오, 그리고 구현 가능성을 체계적으로 기술한다.

현행 전자민원 시스템의 가장 큰 문제는 '민원인이 스스로 담당 부서를 찾아야 한다'는 구조적 전제에서 출발한다. 국민은 자신이 처한 행정적 상황을 일상 언어로 표현하지만, 시스템은 정형화된 분류 체계를 요구한다. 이 간극은 오접수, 재이첩, 부서 간 핑퐁 현상으로 이어지며, 행정 비용 낭비와 국민 불신을 동시에 유발한다. 특히 복합 민원의 경우, 단일 부서로 처리가 불가능함에도 분리 접수·분리 처리 체계가 없어 민원인이 동일 내용을 반복 제출해야 하는 상황이 빈번하게 발생한다.

AI-SPOC은 이 문제를 해결하기 위해 RobertaForSequenceClassification 기반의 자연어 처리 엔진을 핵심으로 삼는다. 본 프로토타입은 hidden_size 768, 12개 레이어, 12개 어텐션 헤드, vocab_size 32,000, max_position_embeddings 514의 모델 구성(model_config.json 참조)을 갖추며, 민원 텍스트를 실시간으로 분석하여 관할 부서를 예측하고 라우팅한다. 총 500개 데이터셋으로 구성된 프로토타입 학습 결과, Accuracy 0.515, Macro F1 0.4579, Top-3 accuracy 0.71의 성능을 기록하였으며(metrics_summary.json 참조), 평균 처리 지연시간은 약 10ms(latency.json 참조)로 실시간 서비스에 적합한 응답 속도를 확인하였다.

라우팅 구조는 신뢰도 임계값(threshold)에 따라 세 가지 경로로 분기된다. 높은 신뢰도의 민원은 담당 부서로 직접 자동 라우팅(Direct)되고, 중간 신뢰도의 경우 AI 코디네이터가 추가 분석을 수행(Coordinator)하며, 낮은 신뢰도의 경우 인간 담당자가 검토하는 Fallback 경로로 전달된다. 현재 프로토타입 실측 기준, Fallback 188건, Coordinator 12건이 기록되었으며

(routing_distribution.json 참조), 이는 Direct Coverage가 극히 낮은 초기 단계임을 나타낸다. 정책 설계 목표는 Direct Coverage 15~35% 달성이며, 이를 위한 임계값 튜닝 전략이 본 제안서에 상세히 기술된다.

동일 집계에서 Direct는 사실상 0건(0% 수준)으로, 초기 단계에서는 보수적 운영을 위해 대부분을 Fallback/Coordinator로 유도하였다.

본 제안서는 기술 아키텍처 설계의 논리적 근거, 단계별 구현 계획, 기대효과 및 KPI를 포함하며, 실제 프로토타입 PROVE 파일들(selective_curve.csv, threshold_grid.csv, confusion_matrix.csv, examples_fallback.jsonl, examples_coordinator.jsonl, sanity.json 등)을 핵심 근거 자료로 활용한다. 본 시스템은 단순한 기술 제안을 넘어, 전자민원 행정 생태계 전반의 구조적 혁신을 위한 실현 가능한 청사진을 제시한다.

I. 문제 정의 및 배경

1.1 전자민원 행정 체계의 구조적 맹점

전자민원 행정 체계는 외형상 디지털화된 것처럼 보이지만, 그 내부 처리 구조는 여전히 아날로그 시대의 부서 할거주의에 기반하고 있다. 민원인은 자신이 처한 문제를 일상적 언어로 기술하지만, 시스템은 미리 정해진 행정 분류 체계에 따라 입력을 처리한다. 이 두 언어 사이의 간극이 바로 전자민원 체계의 가장 근본적인 구조적 맹점이다. 민원인이 "우리 동네 도로가 파손되어 있고, 근처 불법 주정차 차량도 문제인데, 쓰레기도 방치되어 있습니다"라는 복합적 상황을 하나의 민원으로 제출할 때, 현행 시스템은 이를 단일 부서로만 접수하거나, 민원인 스스로가 세 개의 별도 민원으로 분리 제출하도록 요구하는 구조적 한계를 드러낸다. 이처럼 현행 전자민원 체계는 민원인 중심이 아닌 부서 중심의 설계 원리를 따르고 있다는 점에서 근본적인 재설계가 필요하다.

디지털 전환의 물결이 공공행정 영역에도 적용되면서, 대부분의 지방자치단체와 중앙 행정기관은 온라인 민원 접수 창구를 개설하였다. 그러나 이 디지털 창구는 단지 기존의 종이 민원서류를 전자 양식으로 대체한 것에 불과할 뿐, 처리 로직 자체는 변화하지 않았다. 민원인은 여전히 어느 부서에 어떤 민원을 제출해야 하는지를 스스로 파악해야 한다. 이 구조적 전제는 행정에 익숙하지 않은 일반 국민에게 높은 진입 장벽으로 작용하며, 결과적으로 오접수율을 높이고, 처리 부서의 불필요한 업무 부담을 증가시킨다. 행정의 효율화를 위해 도입된 전자민원 시스템이 오히려 비효율을 디지털화하고 있는 역설적 상황이 벌어지고 있는 것이다.

구조적 결함의 첫 번째 원인은 분류 체계와 자연어 표현 간의 불일치이다. 행정 민원 분류 체계는 수십 년에 걸쳐 부서별 업무 범위를 기준으로 설계되어 있다. 도로 관련 민원은 도로교통과, 위생 관련 민원은 환경위생과, 불법 주정차는 교통행정과 등으로 구분된다. 그러나 민원인은 이러한 행정 분류에 익숙하지 않으며, 자신의 상황을 경험한 그대로 기술한다. "집 앞이 너무 위험합니다"라는 표현은 도로 파손일 수도, 불법 주정차일 수도, 가로등 고장일 수도 있다.

민원 텍스트의 모호성과 행정 분류 체계의 엄격성이 충돌하면서, 오접수는 구조적으로 불가피하게 발생한다. 이 문제는 단순히 안내 문구를 개선하거나 분류 메뉴를 확대하는 방식으로 해결할 수 없으며, 자연어를 이해하는 인공지능 기술의 도입을 통해서만 근본적으로 해소될 수 있다.

두 번째 원인은 복합 민원 처리 메커니즘의 부재이다. 실제 지역 사회에서 발생하는 문제는 단일 행정 부서의 관할 경계를 넘는 경우가 많다. 한 도로 구간에서 발생하는 포트홀, 불법 주정차, 야간 조명 부족 문제는 각각 도로과, 교통과, 시설과의 소관 사항이다. 그러나 현행 전자민원 시스템에는 하나의 민원을 여러 부서에 자동으로 분배하는 '복합 민원 분해' 기능이 존재하지 않는다. 민원인이 이 세 가지 문제를 하나의 민원으로 제출하면, 시스템은 임의로 하나의 부서에 배정하거나, 담당자의 판단에 따라 수동으로 이첩하거나, 민원인에게 재제출을 요구한다. 이 과정에서 처리 지연, 담당자 간 책임 회피, 민원의 부분적 처리가 발생하며, 결국 민원인의 실질적 문제는 해결되지 않는 채로 행정 처리만 완료되는 형태가 반복된다.

세 번째 원인은 재이첩 판단 기준의 비표준화이다. 오접수된 민원이 올바른 부서로 이첩되는 과정은 담당 공무원의 개인적 판단과 부서 관행에 의존한다. 동일한 내용의 민원이라도 어느 담당자가 받느냐에 따라 처리 경로가 달라지며, 이첩 기준이 명문화되어 있지 않아 일관성을 확보하기 어렵다. 또한 이첩이 발생할 때마다 민원 처리 기간이 연장되고, 민원인에게 진행 상황이 불투명하게 보이며, 책임 소재가 불분명해진다. 이러한 비표준화된 이첩 구조는 개별 공무원의 업무 부담을 증가시키는 동시에, 행정 서비스의 품질 편차를 구조적으로 고착시키는 요인이 된다. 표준화된 라우팅 알고리즘과 명확한 임계값 기반의 판단 로직이 없는 한, 이 문제는 해결되지 않는다.

- 구조적 결함의 3대 원인

위 본문에서 기술된 바와 같이, 구조적 결함의 3대 원인은 ① 분류 체계와 자연어 표현 간의 불일치, ② 복합 민원 처리 메커니즘의 부재, ③ 재이첩 판단 기준의 비표준화이다. 이 세 가지 원인은 독립적으로 작용하는 것이 아니라 상호 연쇄적으로 작용하며, 전자민원 체계의 비효율

을 구조적으로 고착시키는 악순환을 형성한다. 첫 번째 원인이 오접수를 유발하고, 오접수는 두 번째 원인으로 인해 복합 민원 처리 실패로 이어지며, 두 번째 원인의 결과로 발생하는 이첩은 세 번째 원인으로 인해 비표준화된 채로 반복된다. 이 삼중 연쇄 구조를 동시에 해소하지 않는 한, 부분적인 시스템 개선은 근본적인 변화를 만들어내기 어렵다. AI-SPOC은 이 세 가지 원인 각각에 대응하는 기술 솔루션을 통합적으로 제공함으로써, 악순환의 고리를 끊는 것을 목표로 한다.

1.2 재이첩 반복 구조의 행정비용 분석

재이첩 반복 구조는 전자민원 행정에서 발생하는 행정비용 중 가장 숨겨진 형태의 낭비이다. 표면적으로는 민원이 처리되고 있는 것처럼 보이지만, 실제로는 하나의 민원이 여러 부서를 순환하는 과정에서 행정력이 중복 소모되고, 처리 기한이 연장되며, 담당 공무원의 시간이 실질적 해결이 아닌 이첩 행위 자체에 소비된다. 이 구조적 낭비는 개별 민원 단위에서는 작아 보일 수 있지만, 전체 민원 행정 시스템 관점에서 집계하면 상당한 규모의 비효율로 나타난다. 재이첩이 한 번 발생할 때마다, 발신 부서의 담당자가 이첩 관련 행정 절차를 수행해야 하고, 수신 부서의 담당자는 민원 내용을 처음부터 다시 파악해야 하며, 시스템상 이첩 기록을 남기고 처리 기한을 재산정하는 과정이 반복된다. 이 모든 과정은 실질적인 민원 해결에 기여하지 않는 순수한 행정 오버헤드이다.

재이첩은 단순히 부서 간 전달 행위가 아니라, 민원 처리 전체 흐름을 단절시키는 구조적 장애물이다. 민원이 A 부서에서 B 부서로 이첩될 때, A 부서에서 확보된 민원 맥락과 검토 내용이 온전히 전달되지 않는 경우가 빈번하다. B 부서의 담당자는 이첩된 민원의 배경을 이해하기 위해 추가적인 정보를 수집해야 하거나, 때로는 민원인에게 직접 연락하여 동일한 내용을 다시 확인하는 절차를 거친다. 민원인의 입장에서는 이미 한 번 제출한 정보를 반복 제공해야 하는 상황이 발생하며, 이는 행정에 대한 신뢰를 저하시키는 직접적인 원인이 된다. 또한, 재이첩 과정에서 민원인에게 충분한 상황 설명이 이루어지지 않는 경우, 민원인은 자신의 민원이

어디서 어떻게 처리되고 있는지 파악하지 못한 채로 기다려야 하는 정보 공백 상태에 놓이게 된다.

재이첩 구조가 반복될수록 행정 비용은 기하급수적으로 증가한다. 1차 이첩이 발생하면 두 부서의 인력이 해당 민원에 투입되고, 2차 이첩이 발생하면 세 부서의 인력이 개입하게 된다. 각 이첩 단계에서 담당자의 검토 시간, 이첩 문서 작성 시간, 시스템 처리 시간, 그리고 민원인 응대 시간이 누적된다. 이를 전체 민원 건수에 곱하면, 재이첩으로 인한 행정비용은 전자민원 시스템 운영 총비용의 상당 부분을 차지할 것으로 추정된다. 특히 이첩이 가장 빈번하게 발생하는 복합 민원과 관할 경계 민원의 경우, 1건당 평균 이첩 횟수가 1회를 초과하는 경우도 드물지 않으며, 처리 기간이 법정 기한에 근접하거나 이를 초과하는 사례로 이어질 수 있다.

재이첩 비용 분석의 또 다른 중요한 측면은 '숨겨진 기회비용'이다. 재이첩 처리에 소요되는 담당 공무원의 시간은 본래 민원인의 실질적 문제 해결에 투자되어야 할 시간이다. 오접수 민원을 검토하고 이첩 결정을 내리며 관련 행정 절차를 수행하는 과정에서 소비되는 시간만큼, 해당 공무원은 정상적으로 처리되어야 할 다른 민원들을 처리하지 못한다. 이는 전체 민원 처리 속도를 저하시키고, 처리 대기 중인 다른 민원인들의 대기 시간을 증가시키는 연쇄 효과를 낳는다. 재이첩으로 인한 행정비용은 단순히 이첩 행위 자체의 비용만이 아니라, 이로 인해 지연되거나 희생되는 다른 행정 서비스의 기회비용까지 포함해야 정확하게 평가될 수 있다.

AI-SPOC이 제안하는 사전 라우팅 정확도 향상 전략은 이러한 재이첩 비용 구조를 근본적으로 변화시키기 위한 것이다. 민원이 접수되는 시점에 자연어 처리 엔진이 담당 부서를 정확하게 예측하여 직접 라우팅함으로써, 오접수 자체를 방지하고 재이첩 발생 가능성을 원천적으로 차단하는 것이 핵심 목표이다. 직접 라우팅이 성공하는 경우, 해당 민원에 관여하는 부서는 단 하나이며, 이첩 관련 행정 오버헤드는 발생하지 않는다. AI-SPOC의 Direct Coverage 목표를 15~35%로 설정한 것은, 현실적으로 달성 가능한 수준에서의 재이첩 감소 효과를 극대화하기 위한 정책적 판단이다.

1.3 국민 페르소나 및 상황 설정

- 페르소나 A — 이정민

이정민은 42세의 중소기업 회계팀장으로, 서울 외곽의 단독주택 밀집 지역에 거주하고 있다. 평소 업무 특성상 디지털 기기를 능숙하게 활용하지만, 행정 업무는 거의 경험한 적이 없어 관련 용어나 절차에 익숙하지 않다. 이정민은 어느 날 자신의 주거 단지 앞 도로에서 여러 가지 복합적인 문제를 동시에 발견한다. 도로 가장자리에 포트홀이 발생하여 차량 통행에 위험이 생겼고, 동시에 인도 위에 폐기물로 추정되는 물건들이 수일째 방치되어 있으며, 야간에는 가로등이 꺼진 구간이 있어 보행 안전에도 우려가 된다. 이정민은 이 세 가지 문제를 한 번에 신고하고자 전자민원 시스템에 접속하지만, 어떤 카테고리를 선택해야 할지 처음부터 막막함을 느낀다. 도로 문제는 도로과, 폐기물은 환경과, 가로등은 시설과라는 구분이 있다는 것을 알기 어렵기 때문에 이정민은 '시설물 불편 신고'라는 가장 일반적인 카테고리를 선택하고, 세 가지 내용을 하나의 민원 텍스트에 담아 제출한다.

이정민의 민원은 시설물 불편 신고 담당 부서에 접수되지만, 해당 부서의 업무 범위는 공공시설 내부 시설물에 국한되어 있어 도로 파손, 폐기물, 가로등 문제를 모두 처리하기 어렵다. 담당자는 민원을 검토한 후 각각 도로과, 환경과, 시설과로 분리 이첩하는 결정을 내린다. 그러나 이 이첩 과정에서 민원의 원문은 그대로 전달되지 않고, 각 부서에 맞게 분리된 단편적인 정보만 전달된다. 도로과에서는 포트홀 관련 부분만, 환경과에서는 폐기물 관련 부분만 처리하게 되며, 가로등 문제는 이첩 과정에서 누락되거나 처리 우선순위에서 밀린다. 이정민은 며칠 후 "민원이 처리되었습니다"라는 알림을 받지만, 실제 현장을 확인하면 가로등 문제는 여전히 해결되지 않은 상태이다. 이정민은 행정에 대한 실망감을 갖게 되며, 가로등 문제를 다시 별도로 신고해야 하는 상황에 처하게 된다.

이정민의 사례는 복합 민원에 대한 현행 처리 체계의 가장 전형적인 실패 패턴을 보여준다. 민원인이 자연스럽게 기술한 복합적 상황이 시스템의 단일 분류 구조와 충돌하고, 불완전한 이첩 과정에서 일부 내용이 소실되며, 최종적으로 민원인의 문제가 부분적으로만 해결되는 결과

가 반복된다. AI-SPOC이 이정민과 같은 민원인을 지원하는 방식은 근본적으로 다르다. 이정민이 세 가지 문제를 하나의 텍스트로 제출하더라도, AI 엔진이 복합 민원을 자동으로 분해하여 각 문제를 동시에 해당 부서로 라우팅하고, 모든 문제에 대한 처리 상태를 통합적으로 추적하여 이정민에게 알려준다. 이정민은 세 가지 민원을 별도로 제출할 필요가 없고, 분류 체계를 알 필요도 없으며, 처리 결과를 파편적으로 확인할 필요도 없어진다.

- 페르소나 B — 박수현

박수현은 67세의 은퇴한 교사로, 지방 중소도시의 아파트 단지에 거주하고 있다. 스마트폰은 통화와 문자 전송 정도만 사용할 수 있으며, 인터넷 민원 신고 경험이 전무한 디지털 취약 계층에 해당한다. 박수현은 아파트 단지 인근 골목에서 공사 소음 피해, 주차 불법 점유, 그리고 쓰레기 분리수거 위반으로 인한 악취 문제를 동시에 경험하고 있다. 이웃 주민들의 요청으로 대표로 민원을 제기하게 된 박수현은 아들의 도움을 받아 처음으로 전자민원 시스템에 접속한다. 아들이 시스템을 대신 탐색해 주지만, 세 가지 문제가 각기 다른 부서에 신고해야 한다는 사실을 알지 못한 채 하나의 민원으로 접수를 완료한다. 이 상황은 박수현과 같은 고령층 민원인이 전자민원 시스템을 이용하는 전형적인 방식이다.

박수현의 민원이 시스템에 접수된 후, 담당 공무원은 내용을 검토하고 여러 부서로 분리 이첩을 결정한다. 그러나 이 과정에서 공사 소음 문제가 건설과와 환경과 중 어느 부서 소관인지에 대한 판단이 명확하지 않아, 두 부서 간에 민원이 다시 한 번 이첩되는 상황이 발생한다. 박수현은 처음 민원을 제출한 후 약 2주가 지나도록 아무런 실질적 조치가 이루어지지 않자, 다시 아들에게 도움을 요청하여 처리 현황을 조회한다. 시스템에는 "이첩 처리 중"이라는 상태만 표시되어 있어, 언제 어떤 방식으로 문제가 해결될지 전혀 알 수 없다. 박수현은 행정 불신을 갖게 되고, 결국 직접 구청을 방문하여 대면 민원을 제기하는 방식을 선택한다. 전자민원 시스템을 통한 접근이 더 어렵고 불투명하다는 인식이 고령층 디지털 소외를 심화시키는 악순환의 시작이다.

박수현의 사례는 디지털 취약 계층에게 현행 전자민원 시스템이 얼마나 배타적으로 설계되어

있는지를 단적으로 보여준다. 시스템을 이용하기 위해 타인의 도움이 필요하고, 처리 결과는 불투명하며, 재이첩 과정에서 민원인에게 주도권이 없고, 최종적으로는 오프라인 대면 민원으로 회귀하게 된다는 일련의 흐름은, 전자민원 시스템이 디지털 취약 계층을 사실상 배제하고 있음을 의미한다. AI-SPOC은 박수현과 같은 사용자를 위해 자동 처리 추적, 상태 알림, 그리고 간소화된 입력 방식을 제공한다. 박수현이 문제를 기술한 텍스트 하나만 입력하면, AI 시스템이 분류·분해·라우팅을 자동으로 수행하고, 각 문제의 처리 상태를 실시간으로 알림으로 전달한다. 민원인이 행정 구조를 알지 못해도, 시스템이 민원인을 대신하여 최적의 처리 경로를 탐색하는 것이 AI-SPOC의 설계 철학이다.

1.4 문제의 핵심 정의

앞서 살펴본 구조적 결함과 페르소나 분석을 종합하면, 현행 전자민원 행정 체계가 해결해야 할 핵심 문제는 세 가지 차원으로 압축된다. 첫 번째는 '민원 텍스트의 자연어 다양성과 행정 분류 체계의 불일치' 문제이다. 민원인이 사용하는 언어는 일상적이고 맥락 의존적이지만, 행정 분류 체계는 공식적이고 고정적이다. 이 불일치를 해소하지 않는 한, 오접수는 구조적으로 지속될 수밖에 없다. 두 번째는 '복합 민원 처리 메커니즘의 부재' 문제이다. 실제 민원의 상당 부분은 단일 부서의 관할 범위를 초과하는 복합적 성격을 갖고 있음에도, 현행 시스템은 이를 단일 부서로 배정하거나 민원인에게 분리 제출을 요구하는 구조로 설계되어 있다. 세 번째는 '처리 투명성과 상태 추적의 결핍' 문제이다. 재이첩이 발생하거나 처리 기간이 연장될 때 민원인에게 실시간으로 상황이 공유되지 않으며, 이는 행정 불신의 직접적 원인이 된다.

문제의 핵심을 더욱 명확히 정의하자면, 현행 전자민원 체계의 근본 문제는 '민원인이 행정을 이해해야 한다'는 잘못된 설계 전제에 있다. 이 전제는 디지털 전환 이전부터 존재해 왔으며, 전자민원 시스템은 이를 온라인 환경에 그대로 이식하는 데 그쳤다. 그 결과, 행정 분류 체계를 이해하는 사람만이 시스템을 효과적으로 이용할 수 있고, 복합 문제를 분리하여 여러 부서에 제출할 수 있는 사람만이 완전한 처리를 기대할 수 있으며, 처리 경과를 스스로 추적할 수

있는 사람만이 결과를 확인할 수 있는 배타적 구조가 고착되어 있다. 이 구조에서 가장 큰 피해를 입는 것은 행정에 익숙하지 않은 일반 시민, 고령층, 디지털 취약 계층이다.

AI-SPOC이 해결하고자 하는 문제의 핵심은 따라서 다음과 같이 정의된다. "민원인은 자신의 문제를 자연어로 표현하기만 하면 되고, 나머지 분류·분해·라우팅·추적의 모든 책임은 시스템이 진다." 이 설계 원칙을 실현하기 위해서는 자연어 처리 기반의 관할 예측 모델, 복합 민원 자동 분해 엔진, 부서 간 라우팅 자동화 시스템, 그리고 처리 상태 실시간 알림 체계가 필요하다. 본 제안서는 이 네 가지 기술 요소를 통합한 AI-SPOC 아키텍처를 상세히 제시하며, 각 기술 요소의 설계 근거와 구현 가능성을 프로토타입 PROVE 데이터를 기반으로 논증한다.

결국 문제의 핵심은 기술적 문제인 동시에 행정 철학의 문제이다. 민원인 중심의 서비스 설계를 실현하기 위해서는 기술적 역량과 함께, 부서 경계를 넘는 협업을 가능하게 하는 행정 구조의 변화가 동반되어야 한다. AI-SPOC은 이 두 가지 변화의 교차점에 위치한다. 기술은 자연어 이해와 라우팅 자동화를 통해 민원 처리의 효율성을 높이고, 행정 구조는 AI-SPOC이 제공하는 표준화된 라우팅 로직을 수용함으로써 부서 간 책임 경계를 명확히 할 수 있다. 이 상호 보완적 관계가 AI-SPOC의 근본적인 가치 제안이다.

II. 서비스 시나리오 및 AI 역할 정의

2.1 AI-SPOC 서비스 개요

AI-SPOC(AI-powered Single Point of Contact)은 민원인이 단 하나의 창구를 통해 민원을 제출하면, 인공지능 시스템이 관할 예측·복합 민원 분해·자동 라우팅·상태 추적의 전 과정을 수행하는 통합 민원 지능화 서비스이다. 'Single Point of Contact'라는 명칭은 민원인이 접촉해야 하는 행정 창구를 단 하나로 단일화한다는 설계 철학을 담고 있다. 민원인은 어느 부서에 어떤 민원을 내야 하는지 알 필요가 없으며, 복합 문제를 분리하여 여러 차례 제출할 필요도 없다. AI 시스템이 민원 텍스트를 이해하고, 관할 부서를 결정하며, 여러 부서에 동시 배분하고, 처리 결과를 통합하여 민원인에게 전달한다. 이 서비스 모델은 민원인과 행정 사이의 모든 복잡한 중간 과정을 AI가 담당하게 함으로써, 민원인 경험을 근본적으로 개선하는 것을 목표로 한다.

AI-SPOC의 서비스 구성은 크게 세 개의 기능 계층으로 나뉜다. 첫 번째는 '민원 이해 계층'으로, 자연어 처리 기반의 텍스트 분석 엔진이 민원 내용을 분석하여 핵심 주제를 추출하고, 단일 민원인지 복합 민원인지를 판단하며, 각 주제에 대한 관할 부서 후보를 예측한다. 두 번째는 '라우팅 결정 계층'으로, 신뢰도 임계값 기반의 분기 로직이 예측 결과의 신뢰도를 평가하여 직접 자동 라우팅, 코디네이터 검토, 또는 인간 담당자 Fallback 중 하나의 경로를 선택한다. 세 번째는 '추적 및 알림 계층'으로, 라우팅된 민원의 처리 상태를 실시간으로 모니터링하고, 주요 처리 단계에서 민원인에게 자동으로 상태 알림을 전달한다. 이 세 계층의 유기적 결합이 AI-SPOC의 서비스 완결성을 구성한다.

AI-SPOC의 핵심 기술 엔진은 RobertaForSequenceClassification 기반의 관할 예측 모델이다. 이 모델은 민원 텍스트를 입력으로 받아 각 관할 부서에 대한 확률값을 출력하며, 이 확률값이 라우팅 결정의 기초 데이터로 활용된다. 모델의 구체적 구성은 model_config.json에 명세되어 있으며, 본 프로토타입의 주요 성능 지표는 metrics_summary.json에 기록되어 있다. 프로토타입 단계에서 달성한 성능 수준은 향후 데이터 확대와 모델 개선을 통해 지속적으로 향상될 것

으로 기대된다. 현재 프로토타입의 성능 수준은 초기 개념 검증 단계로서의 의미를 갖는다.

AI-SPOC은 기존 전자민원 시스템을 대체하는 것이 아니라, 기존 시스템의 프론트엔드에 위치하는 지능형 인터페이스로 설계된다. 민원인은 기존과 동일한 방식으로 온라인 또는 모바일로 민원을 접수하지만, 민원 내용이 AI-SPOC 엔진을 거쳐 처리되는 경로가 추가된다. 이 설계 방식은 기존 행정 시스템의 전면 교체 없이도 AI 기반 지능화를 점진적으로 도입할 수 있게 한다는 장점이 있다. 특히, 초기 구축 단계에서는 Fallback 비율이 높더라도 인간 담당자의 검토가 병행되기 때문에, 서비스 품질의 급격한 저하 없이 모델을 지속적으로 개선할 수 있는 안전망이 확보된다.

2.2 As-Is vs. To-Be 민원 처리 흐름

- As-Is: 현행 처리 흐름 (8단계)

현행 전자민원 처리 흐름은 민원인의 의도와 시스템의 처리 구조 사이에 발생하는 간극을 해소하는 메커니즘 없이 설계된 8단계 구조를 따른다. 1단계에서 민원인은 전자민원 포털에 접속하여 민원 유형을 스스로 선택한다. 이 단계에서 민원인은 수십 개의 분류 항목 중 가장 유사해 보이는 것을 선택해야 하지만, 적절한 안내나 지원이 없어 잘못된 분류를 선택하는 경우가 빈번하다. 2단계에서 민원인은 선택한 분류에 해당하는 양식에 민원 내용을 작성하고 제출한다. 이 시점에서 민원은 선택된 분류에 해당하는 담당 부서의 접수 큐에 배정된다. 3단계에서 해당 부서의 담당 공무원이 민원 내용을 검토한다. 내용이 본인 부서의 업무 범위에 해당하지 않는 경우, 담당자는 이첩 결정을 내린다. 4단계에서 이첩 결정이 이루어지고, 민원은 다른 부서로 전달된다. 이 과정에서 민원인에게는 이첩 사실이 시스템 상태 변경으로만 통보되며, 왜 이첩되었는지, 언제 처리될 것인지에 대한 설명은 제공되지 않는 경우가 대부분이다.

5단계에서 이첩을 받은 부서의 담당자가 민원 내용을 다시 검토한다. 이 단계에서도 관할 범위에 해당하지 않는다고 판단되면 재이첩이 발생할 수 있으며, 이 경우 흐름은 4단계로 되돌아간다. 6단계에서 최종 담당 부서가 확정되고 실질적인 처리가 시작된다. 그러나 복합 민원

의 경우, 어느 부서가 최종 담당인지 불분명한 상태에서 복수의 부서가 각자의 영역만 처리하고 나머지는 다른 부서의 처리를 기다리는 조율 부재 상황이 발생할 수 있다. 7단계에서 담당 부서가 처리 결과를 시스템에 등록하고 민원을 완료 처리한다. 8단계에서 민원인에게 처리 완료 알림이 전달된다. 그러나 복합 민원의 경우 일부 문제만 해결된 상태에서 전체 민원이 완료 처리될 수 있어, 민원인은 미해결 문제를 다시 신고해야 하는 상황에 처할 수 있다.

이 8단계 흐름의 핵심적 문제는 처리 경로가 오로지 최초 분류의 정확성에 의존한다는 점이다. 최초 분류가 정확하면 흐름은 원활하지만, 오분류가 발생하는 즉시 이첩 루프에 진입하며, 이 루프에서 벗어나는 데 소요되는 시간과 비용이 전체 처리 효율을 저하시킨다. 또한 복합 민원에 대한 처리 책임이 어느 부서에 있는지 명확하지 않아, 처리 결과의 완전성이 담당자의 재량에 의존하게 된다. 민원인 입장에서 이 과정은 완전히 불투명하며, 시스템이 제공하는 상태 정보는 실질적인 처리 진행 상황을 반영하지 못하는 경우가 많다.

- To-Be: AI-SPOC 적용 처리 흐름

AI-SPOC이 적용된 To-Be 처리 흐름은 민원 접수 단계에서부터 AI가 개입하여 전체 처리 경로를 재설계한다. 1단계에서 민원인은 분류 선택 없이 자유로운 자연어 텍스트로 민원 내용을 작성하여 단일 창구에 제출한다. 분류 체계에 대한 지식이 전혀 없어도 되며, 복합 문제를 하나의 텍스트에 담아도 된다. 2단계에서 AI-SPOC의 자연어 처리 엔진이 실시간으로 민원 텍스트를 분석한다. 이 단계에서 핵심 주제 추출, 관할 부서 예측, 복합 민원 여부 판단이 동시에 이루어지며, 각 예측에 대한 신뢰도 점수가 산출된다. 처리 지연시간은 평균 약 10ms(latency.json 참조)로 민원인이 체감하지 못하는 수준이다. 3단계에서 신뢰도 임계값에 따른 라우팅 분기가 결정된다. 신뢰도가 충분히 높으면 직접 자동 라우팅(Direct), 중간 수준이면 AI 코디네이터 검토(Coordinator), 낮으면 인간 담당자 검토(Fallback)로 분기된다.

4단계에서 Direct 경로의 민원은 해당 부서로 즉시 자동 전달되고, 복합 민원의 경우 분해된 각 문제가 관할 부서에 동시 배분된다. Coordinator 경로의 민원은 AI 코디네이터 모듈이 추가 분석을 수행하여 라우팅 결정의 정확도를 높인 후 전달된다. Fallback 경로의 민원은 인간 담

당자에게 AI의 예측 결과와 신뢰도 점수가 함께 제시되어 의사결정을 지원한다. 5단계에서 각 담당 부서가 실질적인 민원 처리를 시작한다. 이 단계는 현행 처리 흐름과 유사하지만, 오접수나 이첩으로 인한 지연 없이 시작된다는 점에서 근본적으로 다르다. 6단계에서 AI-SPOC의 상태 관리 모듈이 각 담당 부서의 처리 진행 상황을 실시간으로 모니터링하고, 주요 처리 단계별로 민원인에게 자동 알림을 전달한다. 복합 민원의 경우, 각 부문별 처리 상태가 통합 화면에 표시된다. 7단계에서 모든 부문의 처리가 완료되면, AI-SPOC이 완료 결과를 통합하여 민원인에게 전달하고 민원을 최종 완료 처리한다. 민원인은 복합 민원의 모든 문제가 해결되었는지를 단 하나의 통합된 결과 화면에서 확인할 수 있다.

2.3 AI 서비스 단계별 역할 정의

역할 1은 민원 텍스트 실시간 분석이다. 민원인이 제출한 자연어 텍스트는 AI-SPOC의 첫 번째 처리 단계로 진입하여 다층적인 분석 과정을 거친다. 텍스트 전처리 단계에서는 형태소 분석, 불필요한 특수문자 제거, 문장 정규화가 수행된다. 이후 핵심 키워드와 의미 단위가 추출되고, 문맥 이해를 위한 임베딩이 생성된다. 민원 텍스트의 의미적 복잡성을 파악하기 위해 복합 민원 탐지 알고리즘이 동시에 실행된다. 하나의 텍스트에 여러 행정 주제가 포함된 경우, 각 주제를 독립적인 처리 단위로 분리하는 민원 분해 로직이 활성화된다. 이 분석 결과는 관할 예측 모델의 입력으로 전달되어 각 처리 단위별 관할 부서 후보 목록과 신뢰도 점수를 생성하는 데 활용된다. 전체 분석 과정의 평균 처리 시간은 약 10ms 수준으로, 민원인의 제출 즉시 결과가 산출된다.

역할 2는 지능형 관할 예측이다. 텍스트 분석 결과를 바탕으로

RobertaForSequenceClassification 모델이 관할 부서 예측을 수행한다. 이 모델은 민원 텍스트의 의미적 특징을 학습된 분류 기준에 따라 평가하고, 각 관할 부서에 대한 확률값 벡터를 출력한다. 가장 높은 확률값을 가진 부서가 1순위 예측 결과로 선정되며, Top-3 accuracy 기준으로 프로토타입은 0.71의 성능을 기록하였다. 이는 정답 부서가 상위 3개 예측 결과 안에 포함

될 확률이 71%임을 의미한다. 관할 예측의 신뢰도는 단순히 최고 확률값만으로 평가되지 않고, 1순위와 2순위 확률값의 차이, 즉 예측의 명확성도 함께 고려된다. 두 후보 부서 간의 확률 차이가 작은 경우, 시스템은 예측의 모호성을 인식하고 이를 라우팅 결정에 반영한다.

역할 3은 복합 민원 자동 분해이다. 민원 텍스트 분석 과정에서 복수의 행정 주제가 탐지된 경우, AI-SPOC은 해당 민원을 복합 민원으로 분류하고 자동 분해 프로세스를 시작한다. 분해된 각 하위 민원은 독립적인 관할 예측 과정을 거치며, 각각에 대해 신뢰도 점수가 산출된다. 분해된 하위 민원들은 서로 다른 담당 부서로 동시 라우팅될 수 있으며, 각 하위 민원의 처리 상태는 원래 민원의 처리 현황에 통합되어 추적된다. 복합 민원 분해 기능은 현행 시스템에서 발생하는 복합 민원 처리 실패 패턴을 직접적으로 해소하는 핵심 역할을 한다. 분해 로직의 정확성은 전체 서비스 품질에 큰 영향을 미치기 때문에, 프로토타입 개발 이후 지속적인 검증과 개선이 필요한 영역이다.

역할 4는 라우팅 결정 및 자동 전달이다. 관할 예측 결과와 신뢰도 점수를 기반으로 임계값(threshold) 비교를 통한 라우팅 분기 결정이 이루어진다. t_1 이상의 신뢰도를 갖는 경우 Direct 라우팅으로 해당 부서에 자동 전달되고, t_2 이상 t_1 미만의 경우 Coordinator 검토 후 라우팅되며, t_2 미만의 경우 Fallback으로 인간 담당자에게 전달된다. 자동 전달 시 민원의 원문, AI 분석 결과, 예측 신뢰도 정보가 함께 담당 부서 시스템으로 전달되어 처리 담당자의 이해를 돕는다. routing_distribution.json 파일은 프로토타입 테스트 환경에서의 라우팅 분포를 기록하고 있으며, 이를 통해 현재 임계값 설정에서의 각 경로별 분배 비율을 확인할 수 있다.

역할 5는 상태 관리 및 진행 알림이다. 라우팅된 민원의 처리 상태는 AI-SPOC의 상태 관리 모듈에 의해 실시간으로 추적된다. 주요 처리 마일스톤, 예컨대 접수 완료, 담당자 배정, 처리 시작, 현장 확인, 처리 완료 등의 각 단계에서 민원인에게 자동으로 알림이 전달된다. 복합 민원의 경우, 각 하위 민원별 처리 상태가 통합 대시보드에 표시되어 민원인이 전체 진행 현황을 한 눈에 파악할 수 있다. 처리 기한이 임박하거나 초과될 것으로 예측되는 경우, 시스템이 자동으로 담당자에게 경고를 발송하고, 필요시 상위 담당자에게 에스컬레이션 알림을 전송하는

기능도 포함된다. 민원인이 처리 현황을 직접 조회할 수 있는 셀프서비스 인터페이스도 함께 제공된다.

III. 기술 아키텍처 제안

3.1 전체 시스템 아키텍처 개요

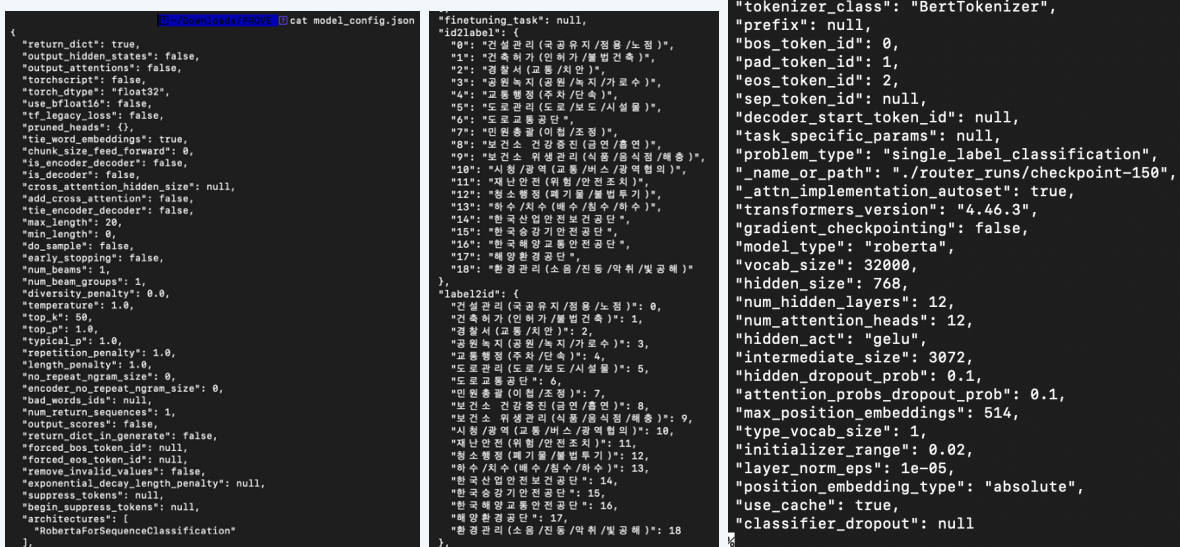
AI-SPOC의 전체 시스템 아키텍처는 민원 접수부터 처리 완료까지의 전체 흐름을 지원하는 다 계층 구조로 설계된다. 최상위 계층은 민원 인터페이스 계층(Presentation Layer)으로, 웹 포털, 모바일 앱, 공공 키오스크 등 다양한 채널을 통한 민원 접수를 수용한다. 이 계층은 민원인과 시스템 간의 상호작용을 담당하며, 접근성 향상을 위한 UI/UX 설계와 다국어 지원을 포함한다. 중간 계층은 AI 처리 계층(AI Processing Layer)으로, 자연어 처리 엔진, 관할 예측 모델, 복합 민원 분해 로직, 신뢰도 평가 모듈, 라우팅 결정 엔진이 위치한다. 이 계층이 AI-SPOC의 핵심 기능을 담당한다. 하위 계층은 행정 연계 계층(Integration Layer)으로, 기존 전자민원 시스템, 각 부서별 업무 시스템, 그리고 민원인 알림 시스템과의 연계 인터페이스를 제공한다.

시스템 아키텍처의 수평적 구성 측면에서는 AI 처리 모듈의 마이크로서비스 분리가 핵심 설계 원칙으로 적용된다. 텍스트 분석 서비스, 관할 예측 서비스, 라우팅 결정 서비스, 상태 관리 서비스를 각각 독립적인 마이크로서비스로 구성함으로써, 서비스별 독립적인 확장과 배포가 가능하고, 특정 서비스의 장애가 전체 시스템에 영향을 미치지 않는 내결함성(fault tolerance)을 확보한다. 각 마이크로서비스는 REST API 또는 비동기 메시지 큐를 통해 상호 통신하며, 전체 시스템의 상태를 모니터링하는 중앙 오케스트레이터가 서비스 간 협력을 조율한다.

데이터 흐름 관점에서 아키텍처를 기술하면, 민원 텍스트는 수신 즉시 비동기 처리 파이프라인에 진입한다. 전처리 단계에서 텍스트 정제와 임베딩이 생성되고, 이 임베딩이 관할 예측 모델의 입력으로 전달된다. 모델 출력인 확률 벡터는 라우팅 결정 엔진으로 전달되며, 임계값 비교를 통해 라우팅 경로가 결정된다. 결정된 경로에 따라 민원 데이터는 해당 처리 모듈(Direct 배정, Coordinator 검토, Fallback 큐)로 전달되고, 최종적으로 행정 연계 계층을 통해 담당 부서 시스템에 등록된다. 이 전체 파이프라인의 처리 지연시간은 latency.json에 기록된 수준으로 관리되며, 실시간성이 요구되는 민원인 인터페이스 응답에 충분히 적합한 성능이다.

모델 서빙 아키텍처는 고가용성과 확장성을 동시에 고려하여 설계된다. 관할 예측 모델은 컨테이너화된 추론 서버로 배포되며, 민원 접수량의 변동에 따라 수평적 자동 확장(horizontal auto-scaling)이 적용된다. 모델 업데이트가 필요한 경우, 블루-그린 배포 전략을 통해 서비스 중단 없이 새로운 모델 버전으로 전환할 수 있다. 모델 성능 모니터링 시스템이 추론 결과의 신뢰도 분포, 라우팅 경로별 분배 비율, 오류 사례 등을 실시간으로 수집하여, 모델 재학습이 필요한 시점을 자동으로 감지하는 피드백 루프를 구성한다. 이 피드백 루프는 AI-SPOC이 운영 데이터를 통해 지속적으로 성능을 향상시키는 핵심 메커니즘이다.

3.2 모델 학습 데이터 설계 상세 기술




```

{
  "return_dict": true,
  "output_hidden_states": false,
  "output_attentions": false,
  "torchscript": false,
  "torch_dtype": "float32",
  "use_bfloat16": false,
  "tf_legacy_loss": false,
  "pruned_heads": {},
  "tie_word_embeddings": true,
  "chunk_size_feed_forward": 0,
  "is_encoder_decoder": false,
  "is_decoder": false,
  "cross_attention_hidden_size": null,
  "add_cross_attention": false,
  "tie_encoder_decoder": false,
  "max_length": 20,
  "min_length": 0,
  "do_sample": false,
  "early_stopping": false,
  "num_beams": 1,
  "num_beam_groups": 1,
  "diversity_penalty": 0.0,
  "temperature": 1.0,
  "top_k": 50,
  "top_p": 1.0,
  "typical_p": 1.0,
  "repetition_penalty": 1.0,
  "length_penalty": 1.0,
  "no_repeat_ngram_size": 0,
  "encoder_no_repeat_ngram_size": 0,
  "bad_words_ids": null,
  "num_return_sequences": 1,
  "output_scores": false,
  "return_dict_in_generate": false,
  "forced_bos_token_id": null,
  "forced_eos_token_id": null,
  "remove_invalid_values": false,
  "exponential_decay_length_penalty": null,
  "suppress_tokens": null,
  "begin_suppress_tokens": null,
  "architectures": [
    "RobertaForSequenceClassification"
  ]
},
{
  "finetuning_task": null,
  "id2label": {
    "0": "건설관리 (국공유지/정용/노점)",
    "1": "건축허가 (인허가/법집행)",
    "2": "경찰서 (교통/치안)",
    "3": "공원녹지 (공원/녹지/가로수)",
    "4": "교통행정 (주차/단속)",
    "5": "도로관리 (도로/보도/시설물)",
    "6": "도로교통공단",
    "7": "민원충돌 (이월/조정)",
    "8": "보건소 건강증진 (금연/흡연)",
    "9": "보건소 위생관리 (식품/음식점/배출)",
    "10": "시청/광역시 (교통/버스/광역철도)",
    "11": "재난안전 (위험/안전조치)",
    "12": "형소행정 (배기물/불법투기)",
    "13": "하수/지수 (배수/침수/하수)",
    "14": "한국산업안전보건공단",
    "15": "한국해양교통안전공단",
    "16": "해양환경공단",
    "17": "환경관리 (소음/진동/악취/빛공해)"
  },
  "label2id": {
    "건설관리 (국공유지/정용/노점)": 0,
    "건축허가 (인허가/법집행)": 1,
    "경찰서 (교통/치안)": 2,
    "공원녹지 (공원/녹지/가로수)": 3,
    "교통행정 (주차/단속)": 4,
    "도로관리 (도로/보도/시설물)": 5,
    "도로교통공단": 6,
    "민원충돌 (이월/조정)": 7,
    "보건소 건강증진 (금연/흡연)": 8,
    "보건소 위생관리 (식품/음식점/배출)": 9,
    "시청/광역시 (교통/버스/광역철도)": 10,
    "재난안전 (위험/안전조치)": 11,
    "형소행정 (배기물/불법투기)": 12,
    "하수/지수 (배수/침수/하수)": 13,
    "한국산업안전보건공단": 14,
    "한국해양교통안전공단": 15,
    "해양환경공단": 16,
    "환경관리 (소음/진동/악취/빛공해)": 17
  },
  "tokenizer_class": "BertTokenizer",
  "prefix": null,
  "bos_token_id": 0,
  "pad_token_id": 1,
  "eos_token_id": 2,
  "sep_token_id": null,
  "decoder_start_token_id": null,
  "task_specific_params": null,
  "problem_type": "single_label_classification",
  "name_or_path": "./router_runs/checkpoint-150",
  "attn_implementation": "autoset": true,
  "transformers_version": "4.46.3",
  "gradient_checkpointing": false,
  "model_type": "roberta",
  "vocab_size": 32000,
  "hidden_size": 768,
  "num_hidden_layers": 12,
  "num_attention_heads": 12,
  "hidden_act": "gelu",
  "intermediate_size": 3072,
  "hidden_dropout_prob": 0.1,
  "attention_probs_dropout_prob": 0.1,
  "max_position_embeddings": 514,
  "type_vocab_size": 1,
  "initializer_range": 0.02,
  "layer_norm_eps": 1e-05,
  "position_embedding_type": "absolute",
  "use_cache": true,
  "classifier_dropout": null
}

```

model_config — RobertaForSequenceClassification 모델의 구조 설정값 (hidden_size 768, 12 layers, 12 attention heads 등)을 확인할 수 있는 구성 파일.



```

{
  "empty_text": 0,
  "unknown_labels": []
}

```

sanity — empty_text 0, unknown_labels 없음 등 학습 데이터 무결성 검증 결과.

AI-SPOC 관할 예측 모델의 학습 데이터 설계는 단순한 데이터 수집과 레이블링을 넘어, 모델이 실제 민원 환경에서 경험하게 될 다양한 어려움을 학습 단계에서 미리 노출시키는 것을 목표로 한다. 현재 프로토타입의 학습 데이터는 총 500개로 구성되며, 이 중 Test set 200개가 성능 평가에 사용되었다. 이 규모는 대규모 상용 서비스에 비하면 소규모이지만, 모델 설계 원칙과 학습 데이터 품질 전략의 개념 검증을 위한 프로토타입으로서의 목적에는 적합하다. 향후 본격적인 시스템 구축 단계에서는 실제 민원 데이터를 대규모로 수집하여 학습 데이터를 확대하는 것이 필수적이다.

데이터 품질 검증 결과, empty_text 0, unknown_labels 없음이 확인되어(sanity.json 참조) 기본적인 데이터 무결성이 확보된 상태임을 확인하였다. 이는 모델 학습에 사용된 모든 데이터 포인트가 실제 텍스트 내용을 갖고 있고, 레이블이 정의된 클래스 범위 안에 있음을 의미한다. 데이터 무결성 확보는 모델 학습의 기본 전제이며, 이를 자동화된 검증 스크립트로 확인하는 프로세스가 데이터 파이프라인에 내재화되어 있다.

HARD Negative 배치 설계는 관할 예측 모델의 변별력을 높이기 위한 핵심 학습 전략이다. 일반적인 분류 학습에서는 각 클래스를 대표하는 전형적인 예시 위주로 학습이 이루어지지만, 이 방식은 경계 사례(boundary case), 즉 두 클래스의 경계에 있는 민원에 대해 모델이 취약한 결과를 낳는다. 예를 들어, 교통사고 관련 민원은 경찰서 소관일 수도 있고 도로교통공단 소관일 수도 있는데, 전형적인 학습만으로는 모델이 이 두 관할 사이의 미묘한 차이를 학습하기 어렵다. HARD Negative 배치는 정답 클래스와 의미적으로 유사하지만 다른 관할인 사례들을 의도적으로 학습 배치에 포함시켜, 모델이 이러한 어려운 경계 사례를 명확히 구분하는 능력을 갖추도록 훈련하는 방법이다. 이 전략은 특히 관할이 중복되거나 혼동되기 쉬운 부서들 사이의 경계 사례에 집중적으로 적용된다.

Whitelist 기반 레이블 통제 전략은 학습 데이터의 레이블 품질을 유지하기 위한 설계 원칙이다. 전자민원 데이터를 대규모로 수집하는 과정에서, 레이블 노이즈(label noise) 문제가 발생할 수 있다. 실제 민원 처리 기록에는 오접수된 민원이 포함되어 있을 수 있으며, 이 오접수 민

원의 원래 배정 부서가 그대로 레이블로 사용될 경우 모델은 잘못된 관할 매핑을 학습하게 된다. Whitelist 기반 레이블 통제는 사전에 정의된 신뢰 가능한 민원-관할 매핑 규칙을 기반으로 레이블의 적절성을 검증하고, 기준에 부합하지 않는 레이블은 수동 검토 대상으로 분류하는 방식이다. 이 전략을 통해 학습 데이터의 레이블 일관성과 신뢰성을 유지하며, 모델이 실제 관할 원칙을 학습하도록 보장한다.

데이터 정합성 확보 방식은 수집된 민원 데이터의 텍스트 품질과 레이블 일관성을 동시에 관리하는 통합적 접근을 취한다. 텍스트 관점에서는 중복 민원 제거, 지나치게 짧은 텍스트 필터링, 개인식별정보(PII) 마스킹이 자동화된 파이프라인으로 처리된다. 레이블 관점에서는 동일한 민원 유형에 대해 서로 다른 레이블이 부여된 불일치 사례를 탐지하고, 레이블 분포의 균형을 모니터링하여 특정 클래스에 편중된 학습이 이루어지지 않도록 관리한다. 데이터 정합성 검증 결과는 sanity.json 파일에 기록되며, 이를 통해 학습 전 데이터 품질의 사전 확인이 가능하다.

- HARD Negative 배치 설계 및 그 이유

HARD Negative 배치는 본 프로토타입의 학습 전략에서 핵심적인 위치를 차지한다.

model_config.json에 명시된 모델 구조(hidden_size 768, 12 layers, 12 attention heads, vocab_size 32000)는 충분한 표현력을 갖추고 있으나, 이 표현력이 실제 경계 사례 구분 능력으로 전환되기 위해서는 학습 데이터 구성 전략이 결정적인 역할을 한다. HARD Negative 배치를 통해 경찰서-도로교통공단, 환경과-시설과 등 혼동이 빈번한 관할 쌍에 대한 집중 학습이 이루어지며, 이는 confusion_matrix.csv에서 확인할 수 있는 혼동 패턴의 개선으로 이어질 것으로 기대된다. 경계 사례의 집중 학습은 전체 Accuracy 향상보다 Macro F1 향상에 더 큰 영향을 미치는데, 이는 클래스 불균형 상황에서도 소수 클래스에 대한 분류 성능을 균형 있게 향상시키기 때문이다. 프로토타입의 Macro F1(0.4579)과 Weighted F1(0.4597)의 차이가 크지 않다는 점은 현재 학습 데이터의 클래스 분포가 일정 수준의 균형을 갖추고 있음을 시사하며, 이 균형은 Whitelist 기반 레이블 통제 전략의 결과이기도 하다.

- Whitelist 기반 레이블 통제 전략

Whitelist 기반 레이블 통제는 sanity.json에서 확인된 데이터 무결성(empty_text 0, unknown_labels 없음)의 근간이 되는 전략이다. 민원 행정 데이터는 그 특성상 레이블 노이즈가 발생하기 쉬운 환경을 갖는다. 실제 처리 이력 기반의 레이블은 오접수된 민원의 잘못된 배정 부서를 그대로 레이블로 사용하는 경우가 있으며, 이러한 노이즈 레이블이 학습 데이터에 포함되면 모델이 잘못된 관할 매핑을 학습한다. Whitelist 기반 레이블 통제는 이를 방지하기 위해 사전에 검증된 관할 원칙에 부합하는 레이블만을 학습에 사용하도록 통제한다. 이 통제 과정에서 불확실한 레이블을 가진 데이터는 학습에서 제외되거나 수동 검토 대상으로 분류된다. 이는 단기적으로는 학습 데이터 규모를 감소시킬 수 있지만, 장기적으로는 모델이 실제 관할 원칙을 정확하게 학습하는 데 기여한다.

- 데이터 정합성 확보 방식

데이터 정합성 확보는 sanity.json의 자동화된 검증 프로세스를 통해 이루어진다. 검증 항목에는 텍스트 공백 여부(empty_text), 레이블 범위 초과 여부(unknown_labels), 중복 데이터 존재 여부, 클래스 분포 편향 수준이 포함된다. 이 자동화된 검증은 학습 파이프라인 내에 통합되어 있으며, 검증 기준을 통과하지 못한 데이터는 자동으로 격리되어 수동 검토 큐로 전달된다. 데이터 정합성 검증 결과를 파일로 기록하고 버전 관리하는 것은 모델 성능 변화를 데이터 품질 변화와 연계하여 분석하는 데도 중요하다. 현재 프로토타입에서 확인된 empty_text 0, unknown_labels 없음이라는 결과는 기본적인 데이터 정합성 요건이 충족되어 있음을 보여주며, 이는 관찰된 성능 수치가 데이터 품질 문제가 아닌 모델 자체의 한계에서 비롯된 것임을 시사한다.

3.3 임계값(Threshold) 튜닝 전략

```

~/Downloads/PROVE cat selective_curve.csv
coverage,kept_N,kept_accuracy
1.0,200,0.515
0.9,180,0.5333
0.8,160,0.5563
0.7,140,0.5786
0.6,120,0.5917
0.5,100,0.62
0.4,80,0.65
0.3,60,0.65
0.2,40,0.7
0.1,20,0.7

```

selective_curve — 임계값 변화에 따른 Direct Coverage와 Accuracy 간의 trade-off 관계를 시각화한 곡선.

```

kim_jinwoong@MacBookPro ~/Downloads/PROVE cat threshold_grid.csv
t1,t2,direct_coverage,direct_acc,fallback_rate
0.6,0.05,0.04,0.625,0.94
0.6,0.1,0.04,0.625,0.94
0.6,0.15,0.04,0.625,0.94
0.6,0.2,0.04,0.625,0.94
0.6,0.25,0.04,0.625,0.94
0.65,0.05,0.02,0.75,0.94
0.65,0.1,0.02,0.75,0.94
0.65,0.15,0.02,0.75,0.94
0.65,0.2,0.02,0.75,0.94
0.65,0.25,0.02,0.75,0.94
0.7,0.05,0.0,0.94
0.7,0.1,0.0,0.94
0.7,0.15,0.0,0.94
0.7,0.2,0.0,0.94
0.7,0.25,0.0,0.94
0.72,0.05,0.0,0.94
0.72,0.1,0.0,0.94
0.72,0.15,0.0,0.94
0.72,0.2,0.0,0.94
0.72,0.25,0.0,0.94
0.75,0.05,0.0,0.94
0.75,0.1,0.0,0.94
0.75,0.15,0.0,0.94
0.75,0.2,0.0,0.94
0.75,0.25,0.0,0.94

```

threshold_grid — t1, t2 조합별 Direct / Coordinator / Fallback 분기 비율과 정확도를 분석한 격자 탐색 결과.

임계값(Threshold) 튜닝 전략은 AI-SPOC 라우팅 시스템의 성능과 신뢰성을 동시에 관리하기 위한 핵심 설계 요소이다. 관할 예측 모델이 출력하는 확률 점수는 연속적인 값을 갖는 반면, 라우팅 결정은 이산적인 경로 선택을 요구한다. 이 연속값을 이산 결정으로 변환하는 기준점이 바로 임계값이며, 임계값의 설정에 따라 자동 처리 비율과 처리 정확도 사이의 균형이 결정된다.

t1, t2 정의 및 라우팅 분기 구조를 살펴보면, 본 시스템은 두 개의 임계값을 사용하는 3-way 분기 구조를 채택한다. t1은 상위 임계값으로, 예측 신뢰도가 t1 이상인 경우 AI가 충분히 확신을 갖고 있다고 판단하여 Direct 라우팅, 즉 해당 부서로의 자동 직접 전달을 수행한다. t2는 하위 임계값으로, 예측 신뢰도가 t2 이상 t1 미만인 경우 Coordinator 경로로 분기되어 추가적인 AI 분석이나 보조적 검증을 거친 후 라우팅된다. 신뢰도가 t2 미만인 경우 Fallback 경로로 분기되어 인간 담당자의 직접 판단을 요청한다. threshold_grid.csv 파일은 다양한 t1, t2 조합에 따른 각 경로별 커버리지와 정확도를 격자 탐색한 결과를 기록하고 있으며, 이를 통해 최적 임계값 조합을 데이터 기반으로 선정할 수 있다.

Coverage vs Accuracy Trade-off는 임계값 튜닝의 핵심 과제이다. t1 값을 낮게 설정하면 Direct Coverage, 즉 자동 라우팅 비율이 증가하지만, 그만큼 신뢰도가 낮은 예측도 자동 처리되어 라우팅 오류 가능성이 높아진다. 반대로 t1 값을 높게 설정하면 Direct Coverage는 낮아지지만, 자동 처리되는 민원에 대한 정확도는 향상된다. selective_curve.csv는 다양한 임계값 수준에서의 Coverage와 Accuracy 관계를 기록하고 있으며, 이 곡선을 분석하면 Coverage 증가에 따른 Accuracy 저하 속도를 파악하여 수용 가능한 최적 균형점을 찾는 데 활용된다. 이 Trade-off 분석은 단순히 기술적 최적화의 문제가 아니라, 행정 서비스에서 어느 수준의 자동화 오류율을 허용할 것인가에 대한 정책적 결정을 포함한다.

Direct Coverage 15~35%는 정책 설계 목표 범위로 설정된 수치이다. 이 목표 범위는 두 가지 고려에서 도출된다. 첫 번째는 현실적인 구현 가능성이다. 현재 프로토타입 실측값은 극히 낮은 Direct Coverage를 기록하고 있으며, 이는 500개라는 소규모 학습 데이터와 초기 모델의 한계를 반영한다. 향후 대규모 학습 데이터와 모델 개선이 이루어진 후, 현실적으로 달성 가능한 목표 수준으로서 15~35% 범위가 설정된 것이다. 두 번째는 행정 위험 관리의 관점이다.

Direct 라우팅이 오류를 발생시키면 오접수와 동일한 결과를 초래하므로, 무조건 높은 Coverage를 추구하기보다는 충분한 정확도가 보장되는 범위 내에서의 자동화를 목표로 삼는다. 35%를 초과하는 높은 Coverage 목표는 현재 기술 수준에서 정확도를 희생하는 결과를 낳

을 가능성이 높다고 판단하였다.

본 프로토타입은 오분류에 따른 행정 리스크를 최소화하기 위해 초기 단계에서 보수적인 임계값 정책을 적용하였으며, 이에 따라 Direct Routing 비율은 낮게 유지되었다.

Fallback 과부하 방지 논리는 임계값 튜닝과 밀접하게 연결된 운영 안전 장치이다. t2 값이 지나치게 높게 설정되면 대부분의 민원이 Fallback 경로로 분기되어 인간 담당자의 처리 큐가 과부하 상태에 빠진다. 이는 오히려 현행 수동 처리 체계보다 비효율적인 결과를 낳을 수 있다. 반대로 t2 값이 지나치게 낮으면 신뢰도가 매우 낮은 예측도 Coordinator 경로로 유입되어 Coordinator 모듈에 과부하가 발생한다. 이러한 과부하를 방지하기 위해, 각 경로별 처리 용량 한도를 설정하고, 특정 경로의 처리 큐가 한도를 초과하면 임계값을 동적으로 조정하는 적응형 임계값 관리 메커니즘을 도입한다. 이 메커니즘은 민원 접수량의 급격한 변동이나 특정 유형의 민원이 집중되는 상황에서도 각 처리 경로가 안정적으로 운영될 수 있도록 보장한다.

3.4 오류 분석 (Error Analysis)

```

C:\Downloads\PROVE cat confusion_matrix.csv
,건설관리(국공유지/점용/노점),건축허가(인허가/불법건축),경찰서(교통/치안),공원녹지(공원/녹지/가로수),
,교통행정(주차/단속),도로관리(도로/보도/시설물),도로교통공단,민원총괄(이첩/조정),보건소 건강증진(금
연/흡연),보건소 위생관리(식품/음식점/해충),시청/광역(교통/버스/광역철의),재난안전(위험/안전조치),청
소행정(폐기물/불법투기),하수/치수(배수/침수/하수),한국산업안전보건공단,한국승강기안전공단,한국해양교
통안전공단,해양환경공단,환경관리(소음/진동/악취/빛공해)
건설관리(국공유지/점용/노점),6,0,1,6,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0
건축허가(인허가/불법건축),1,6,0,1,0,0,0,2,0,0,0,0,0,1,0,0,0,0,0,0
경찰서(교통/치안),2,0,11,0,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0,1
공원녹지(공원/녹지/가로수),0,0,0,11,0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0
교통행정(주차/단속),0,0,0,0,9,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0
도로관리(도로/보도/시설물),0,0,2,13,1,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0
도로교통공단,0,0,7,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0
민원총괄(이첩/조정),1,1,0,4,0,0,0,2,0,0,0,0,0,0,0,0,0,0,0,1
보건소 건강증진(금연/흡연),0,0,0,0,0,0,0,0,5,0,0,0,0,0,0,0,0,0,0,0
보건소 위생관리(식품/음식점/해충),2,0,0,1,0,0,0,0,0,0,0,0,6,0,0,0,0,0,0,0
시청/광역(교통/버스/광역철의),0,0,7,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0
재난안전(위험/안전조치),0,0,0,9,0,0,0,0,0,1,0,0,0,1,1,0,0,0,0,0
청소행정(폐기물/불법투기),0,0,0,0,0,0,0,0,0,0,0,0,9,0,0,0,0,0,0,0
하수/치수(배수/침수/하수),0,0,0,1,0,0,0,0,0,0,0,0,0,0,12,0,0,0,0,0
한국산업안전보건공단,0,0,0,0,0,0,0,0,0,0,0,0,0,0,7,0,0,0,0,0
한국승강기안전공단,0,1,0,5,0,0,0,0,0,0,0,0,0,0,4,0,0,0,1
한국해양교통안전공단,0,0,3,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0
해양환경공단,0,0,1,1,0,0,0,0,0,0,0,0,4,4,0,0,0,0,0,0
환경관리(소음/진동/악취/빛공해),0,0,2,1,0,0,0,0,0,0,0,0,1,0,0,0,0,0,14
  
```

confusion_matrix — 관할 클래스 간 오분류
패턴을 행렬 형태로 나타낸 혼동 분석 결과.

[illegible]

examples — examples_fallback.jsonl 및 examples_coordinator.jsonl 파일로, Fallback 및 Coordinator 경로로 분기된 실제 민원 텍스트 사례를 확인할 수 있는 자료.

오류 분석(Error Analysis)은 AI-SPOC 모델의 현재 한계를 정직하게 파악하고, 향후 개선 방향을 구체적으로 수립하기 위한 핵심 분석 과정이다. 프로토타입 실측 결과인 Accuracy 0.515, Macro F1 0.4579는 현재 단계에서의 모델 성능을 정직하게 반영하며, 이 수치를 통해 어떤 유형의 오류가 가장 빈번하고 심각한지를 파악하는 것이 중요하다. `confusion_matrix.csv` 파일은 각 클래스 간의 혼동 패턴을 기록하고 있으며, 이를 분석하면 특정 관할 쌍 사이에서 오류가 집중되는 구조적 패턴을 발견할 수 있다.

경찰서 vs 도로교통공단 혼동 분석은 관할 예측에서 가장 전형적으로 발생하는 오류 패턴의 하나이다. 교통 관련 민원은 내용에 따라 경찰서(교통사고, 불법 주정차 단속, 신호 위반 등)와 도로교통공단(도로 안전시설 설치, 교통안전 교육 등)으로 관할이 나뉘지만, 민원 텍스트에서 이 두 관할을 구분하는 언어적 표지는 매우 미묘하다. "교차로에서 사고가 날 뻔 했어요. 신호등 문제가 있는 것 같아요"라는 텍스트는 경찰서(교통 위험 신고)와 도로교통공단(신호등 시설물 문제) 두 관할 모두와 관련될 수 있다. 혼동 행렬 분석을 통해 이러한 경계 사례에서의 오분류 빈도를 정량적으로 파악하고, HARD Negative 배치를 통해 모델이 이 경계를 더 명확히 학

습하도록 유도하는 것이 개선 전략의 핵심이다.

다부서 민원 Ambiguity 문제는 단일 관할 예측 프레임워크에서 근본적으로 해결하기 어려운 구조적 도전이다. 복합 민원의 경우 단일한 '정답 관할'이 존재하지 않기 때문에, 분류 모델의 정확도 지표만으로는 이 문제의 심각성을 충분히 포착하지 못한다. examples_fallback.jsonl과 examples_coordinator.jsonl 파일에 기록된 사례들은 현재 모델이 처리하기 어렵다고 판단하여 자동 라우팅을 유보한 민원들의 구체적인 텍스트 패턴을 보여준다. 이 사례 분석을 통해 Ambiguity가 주로 발생하는 민원 유형을 파악하고, 복합 민원 분해 로직의 개선 방향과 Coordinator 모델의 추가 처리 전략을 구체화할 수 있다.

Coordinator 모델 정확도 0.75는 프로토타입에서 기록된 수치이며, 이를 해석함에 있어 신중한 접근이 필요하다. 0.75라는 수치는 Coordinator 경로로 유입된 12건의 사례 (routing_distribution.json 참조)에서의 결과를 반영하는 것으로, 매우 제한된 표본 수에 기반한 측정임을 고려해야 한다. 이 수치를 Coordinator 모델의 최종적인 성능 평가로 단정하기보다는, 대규모 데이터에서 재측정이 필요한 초기 탐색 결과로 해석하는 것이 적절하다.

Coordinator 경로에서의 정확도를 보다 신뢰성 있게 평가하기 위해서는 더 많은 테스트 사례의 수집과 추가 분석이 필요하며, 이는 Phase 2 개발 단계에서 구체적으로 수행될 예정이다.

3.5 Multi-Agent AI 아키텍처

Multi-Agent AI 아키텍처는 AI-SPOC이 단순한 분류 모델을 넘어, 복잡한 민원 처리 시나리오에 유연하게 대응할 수 있는 지능적 시스템으로 진화하기 위한 설계 기반이다. 에이전트 기반 아키텍처에서는 특정 역할을 담당하는 복수의 AI 에이전트가 상호 협력하여 전체 민원 처리 파이프라인을 구성한다. 각 에이전트는 독립적인 기능 단위로 설계되어 있어, 특정 에이전트의 성능 개선이나 교체가 전체 시스템의 재구축 없이도 가능하다. 이 모듈성은 AI-SPOC의 지속적인 성능 향상과 기능 확장을 용이하게 하는 핵심 설계 원칙이다.

에이전트 구성은 세 가지 주요 역할로 나뉜다. 첫 번째는 분류 에이전트(Classification Agent)

로, RobertaForSequenceClassification 모델을 포함하며 민원 텍스트의 관할 분류를 담당한다. 두 번째는 분해 에이전트(Decomposition Agent)로, 복합 민원을 독립적인 하위 민원으로 분리하고 각 하위 민원에 대한 관할 예측을 지원한다. 세 번째는 코디네이터 에이전트 (Coordinator Agent)로, 분류 에이전트의 결과가 불확실하거나 복수의 관할 후보가 경쟁하는 경우, 추가적인 정보 수집과 분석을 통해 최종 라우팅 결정을 도출한다. 이 세 에이전트는 각자의 역할을 수행하면서 중앙 오케스트레이터를 통해 협력하며, 오케스트레이터는 각 에이전트의 처리 결과를 통합하여 최종 라우팅 결정을 생성한다.

에이전트 간 통신 프로토콜은 표준화된 메시지 포맷을 통해 이루어진다. 각 에이전트는 처리 결과를 구조화된 JSON 형태로 출력하며, 이 메시지에는 분석 결과, 신뢰도 점수, 그리고 다음 에이전트에게 전달할 컨텍스트 정보가 포함된다. 비동기 메시지 큐를 활용하여 에이전트 간 결합도를 낮추고, 특정 에이전트의 처리 지연이 전체 파이프라인의 응답 시간에 미치는 영향을 최소화한다. 에이전트 처리 결과와 중간 상태는 중앙 로그 저장소에 기록되어, 이후 성능 분석과 오류 추적에 활용된다.

3.6 신뢰도 점수 구조

신뢰도 점수 구조는 AI-SPOC 라우팅 결정의 투명성과 설명 가능성을 보장하기 위한 핵심 설계 요소이다. 신뢰도 점수는 단순히 모델 출력의 최대 확률값이 아니라, 여러 신뢰성 지표를 종합한 복합 점수로 구성된다. 기본 신뢰도는 관할 예측 모델의 softmax 출력에서 최고 확률값으로 산출된다. 이에 더하여, 1순위와 2순위 확률값의 차이(margin)가 고려되는데, 이 차이가 작을수록 예측이 모호하다는 신호로 해석된다. 또한 입력 텍스트가 학습 데이터의 분포에서 얼마나 벗어나 있는지를 나타내는 분포 외 탐지(out-of-distribution detection) 점수도 신뢰도 산출에 포함될 수 있다.

신뢰도 점수의 구성 요소를 통합하여 단일 점수를 산출하는 집계 방식은 각 요소의 가중치를 어떻게 설정하느냐에 따라 결과가 달라지므로, 운영 데이터 분석을 통한 가중치 최적화가 지

속적으로 수행되어야 한다. 신뢰도 점수는 라우팅 결정에 활용되는 것은 물론, 인간 담당자가 Fallback 민원을 검토할 때 AI가 왜 자동 처리를 유보하였는지를 이해하는 설명 자료로도 활용된다. 이는 AI 시스템에 대한 인간 담당자의 신뢰를 형성하고, 인간-AI 협력의 효과성을 높이는 데 중요한 역할을 한다. 신뢰도 점수 기반의 라우팅 결정 투명성은 AI 행정 서비스의 공정성과 설명 책임성(accountability) 요건을 충족하는 데도 기여한다.

3.7 연계 구조 및 실시간 처리 가능성

```
kim_jinwoong@MacBookPro ~/Downloads/PROVE cat routing_distribution.json
{
  "fallback": 188,
  "coordinator": 12
}
```

routing_distribution — 프로토타입 테스트에서 Fallback 188건,
Coordinator 12건으로 집계된 라우팅 분포 현황.

연계 구조 및 실시간 처리 가능성은 AI-SPOC을 기존 전자민원 행정 생태계에 실질적으로 통합하기 위한 기술적 기반이다. AI-SPOC이 독립적인 기술 시스템으로 존재하더라도, 기존 부서별 업무 시스템과 실질적으로 연계되지 않으면 민원 자동 라우팅의 효과는 구현되지 않는다. 연계 구조 설계는 표준 API 인터페이스를 기반으로 하며, 각 부서 시스템의 민원 접수 엔드포인트에 AI-SPOC의 라우팅 결정을 자동으로 전달하는 메커니즘이 필요하다.

실시간 처리 가능성은 latency.json에 기록된 평균 약 10ms의 추론 지연시간을 통해 기술적으로 뒷받침된다. 민원인이 제출 버튼을 누른 후 AI 분석 결과가 생성되기까지의 시간이 10ms 수준이라면, 사용자 경험 관점에서 완전히 투명한 수준으로 실시간 처리가 가능하다. 다만, 실제 서비스 환경에서는 네트워크 지연, 행정 연계 시스템의 응답 시간, 복합 민원 분해 로직의 추가 처리 시간 등이 총 지연시간에 합산되므로, 엔드-투-엔드 응답 시간은 별도로 측정 및 최적화가 필요하다. 비동기 처리 파이프라인을 활용하면 민원인에게는 즉각적인 접수 완료 응답을 제공하면서, AI 분석과 라우팅은 백그라운드에서 완료되는 방식으로 사용자 경험과 처리

효율성을 동시에 확보할 수 있다.

3.8 데이터 레이어 설계

데이터 레이어 설계는 AI-SPOC의 지속적인 학습과 성능 향상을 지원하는 인프라적 기반이다. 데이터 레이어는 크게 운영 데이터 저장소, 모델 학습 데이터 저장소, 그리고 모델 성능 모니터링 데이터 저장소로 구성된다. 운영 데이터 저장소에는 실시간으로 처리되는 민원 텍스트, AI 예측 결과, 라우팅 결정, 처리 결과가 기록된다. 이 데이터는 개인식별정보가 마스킹된 형태로 저장되며, 모델 재학습을 위한 신규 학습 데이터 수집의 주요 원천이 된다. 모델 학습 데이터 저장소는 레이블이 검증된 민원-관할 매핑 데이터를 관리하며, 버전 관리를 통해 학습 데이터의 이력을 추적한다. 모델 성능 모니터링 저장소에는 각 민원 처리 건별 예측 정확도, 신뢰도 점수, 라우팅 경로 등이 기록되어, 실시간 성능 대시보드와 주기적 성능 보고서 생성에 활용된다.

데이터 레이어의 핵심 과제는 운영 중에 수집되는 실제 민원 데이터를 안전하고 효과적으로 모델 학습에 활용하는 피드백 루프를 구축하는 것이다. 자동 라우팅된 민원의 처리 결과가 AI 예측의 정확성을 검증하는 레이블로 활용될 수 있으며, 담당자가 AI 예측을 수정한 사례는 특히 고품질의 학습 데이터가 된다. 이 피드백 루프가 안정적으로 운영되면, AI-SPOC은 운영 기간이 길어질수록 성능이 향상되는 자가 개선 시스템으로 발전한다. 다만, 이 피드백 루프가 잘 못 설계되면 편향된 데이터가 지속적으로 학습되는 '피드백 루프 편향' 문제가 발생할 수 있으므로, 데이터 품질 검증과 편향 모니터링이 함께 수행되어야 한다.

3.9 개인정보 보호 및 보안 설계

개인정보 보호 및 보안 설계는 민원 데이터가 포함하는 민감한 개인정보를 적절히 보호하면서도 AI 시스템의 기능적 요건을 충족하기 위한 균형 잡힌 접근을 요구한다. 민원 텍스트에는 이름, 주소, 전화번호, 주민등록번호 등의 직접 개인식별정보는 물론, 특정 개인의 생활 상황과 문제를 드러내는 민감한 맥락 정보가 포함될 수 있다. 이러한 정보는 AI 모델의 학습과 추론에

활용될 수 있지만, 동시에 엄격한 보호 조치 하에 관리되어야 한다.

기술적 보호 조치로는 데이터 저장 시 암호화, 전송 구간 SSL/TLS 적용, 모델 학습 데이터에서의 PII 자동 마스킹이 기본으로 적용된다. AI 모델 학습 과정에서 특정 개인의 정보를 모델이 기억하지 않도록 하는 차등 프라이버시(Differential Privacy) 기법의 적용 가능성도 검토된다. 접근 제어 측면에서는 역할 기반 접근 제어(RBAC)를 통해 데이터에 대한 접근 권한을 최소화 하고, 모든 데이터 접근 행위에 대한 감사 로그를 기록한다. 법적 보호 측면에서는 개인정보 보호법 및 관련 행정 규정에 따른 데이터 보유 기간 준수, 열람·삭제 요청 대응 체계 구축이 필요하다. AI-SPOC이 처리하는 민원 데이터는 행정 목적으로만 사용되며, 제3자 제공이나 마케팅 목적의 활용이 엄격히 금지된다는 원칙이 시스템 설계 전반에 내재화되어야 한다.

IV. 개발범위 및 단계별 구현 계획

4.1 개발범위 정의

AI-SPOC의 개발범위는 핵심 기능과 지원 기능으로 구분되며, 각 기능의 우선순위는 구현 가능성, 행정 효과, 기술적 준비도를 종합하여 결정된다. 핵심 기능 범위에는 자연어 민원 텍스트 분석 엔진, 관할 예측 모델 및 서빙 시스템, 신뢰도 기반 3-way 라우팅 결정 엔진, 라우팅 결과 전달 API, 그리고 처리 상태 추적 및 알림 시스템이 포함된다. 지원 기능 범위에는 모델 학습 데이터 관리 시스템, 임계값 튜닝 도구, 성능 모니터링 대시보드, 관리자 인터페이스, 그리고 기존 전자민원 시스템과의 연계 인터페이스가 포함된다. 개발범위에서 의도적으로 제외된 영역은 기존 부서별 업무 처리 시스템의 개편과 민원인 대면 채널의 전면 재설계이다. AI-SPOC은 기존 시스템의 프론트엔드에 위치하는 추가 지능 계층으로 설계되므로, 기존 시스템의 변경을 최소화하는 것이 원칙이다.

개발범위 결정의 핵심 원칙은 '점진적 가치 창출'이다. 전체 시스템을 한 번에 구축하려 할 경우 초기 투자 규모가 커지고 리스크가 집중되는 반면, 핵심 기능부터 순차적으로 구현하면 각 단계에서 실제 운영 데이터를 수집하여 다음 단계의 설계를 개선하는 학습 효과를 얻을 수 있다. 프로토타입에서 검증된 기술 요소들, 즉 모델 구조, 라우팅 분기 로직, 데이터 파이프라인은 Phase 1 개발의 기반으로 직접 활용된다. 프로토타입 PROVE 파일들에 기록된 성능 지표와 분포 데이터는 Phase 1 목표 설정과 임계값 초기 설정의 근거 자료가 된다. 개발범위의 경계를 명확히 설정하는 것은 프로젝트 범위 크리프(scope creep)를 방지하고, 각 단계에서 명확한 완료 기준을 유지하기 위해서도 중요하다.

4.2 단계별 구축 방안

- Phase 1

- Phase 2

- Phase 3

Phase 1은 핵심 AI 엔진과 기본 라우팅 파이프라인 구축에 집중하는 단계이다. 이 단계에서는 프로토타입에서 개념 검증된 RobertaForSequenceClassification 기반 관할 예측 모델을 프로덕션 수준으로 발전시키는 것이 주요 목표이다. 학습 데이터를 현재 500개에서 대폭 확대하여 모델 성능을 실질적인 운영 수준으로 향상시킨다. 구체적으로는 실제 민원 데이터를 수집하고 레이블링하는 데이터 구축 작업이 이 단계의 핵심 선행 과제이다. 모델 학습·검증·배포 파이프라인을 자동화하고, 기본적인 A/B 테스트 프레임워크를 구축하여 모델 업데이트 시 성능 변화를 안전하게 검증하는 체계를 마련한다. Phase 1의 라우팅 시스템은 단일 관할 민원에 대한 직접 라우팅과 Fallback 경로를 우선 구현하며, Coordinator 경로는 Phase 2에서 구현한다. 기존 전자민원 시스템과의 기본 연계 인터페이스를 구축하여, 라우팅 결정이 실제 담당 부서 시스템으로 전달되는 엔드-투-엔드 흐름을 완성한다. Phase 1 완료 기준은 Accuracy 기준 프로토타입 대비 유의미한 향상이 확인되고, 기본 라우팅 파이프라인이 안정적으로 운영되며, Direct Coverage가 목표 범위의 하한인 15%에 근접하는 것이다.

Phase 2는 복합 민원 처리와 Coordinator 에이전트 구현에 집중하는 단계이다. Phase 1에서 구축된 기반 위에 복합 민원 자동 분해 엔진을 추가하고, Coordinator 에이전트의 추가 분석 로직을 구현한다. 복합 민원 분해 엔진 개발을 위해서는 복합 민원 사례를 충분히 수집하고 분해 패턴을 레이블링하는 전용 데이터 구축이 선행되어야 한다. Coordinator 에이전트는 분류 에이전트의 불확실한 예측을 받아 추가적인 컨텍스트 분석, 유사 민원 사례 검색, 또는 규칙 기반 관할 결정 로직을 적용하여 라우팅 정확도를 개선하는 역할을 수행한다. 상태 관리 및 알림 시스템도 이 단계에서 본격적으로 구현되어, 민원인에게 실시간 처리 상태를 제공하는 기능이 활성화된다. Phase 2 완료 기준은 복합 민원 분해 기능이 실제 복합 민원 사례에서 유의미한 분해 정확도를 달성하고, Coordinator 경로에서의 라우팅 정확도가 Fallback 대비 통계적으로 유의미한 개선을 보이며, 민원인 대상 상태 알림 기능이 안정적으로 운영되는 것이다.

Phase 3은 시스템 최적화와 지속적 개선 체계 구축에 집중하는 단계이다. Phase 1과 Phase 2

에서 수집된 운영 데이터를 기반으로 모델을 재학습하고 임계값을 최적화하여, Direct Coverage를 목표 범위 내에서 지속적으로 향상시킨다. 성능 모니터링 대시보드를 고도화하여, 관리자가 라우팅 분포, 정확도 추이, 처리 기한 준수율 등을 실시간으로 파악할 수 있는 운영 가시성을 확보한다. 장기적인 시스템 자가 개선을 위한 피드백 루프 자동화, 즉 운영 데이터에서 고품질 학습 데이터를 자동으로 추출하고 모델 재학습을 트리거하는 파이프라인을 완성한다. 또한, 시스템 확장성을 검증하는 부하 테스트와 장애 복구 시나리오 점검이 이 단계에서 수행된다. Phase 3 완료 기준은 Direct Coverage 15~35% 목표 범위 달성, 시스템 가용성 99.9% 이상, 그리고 모델 재학습 주기가 자동화된 파이프라인 내에서 안정적으로 운영되는 것이다.

4.3 프로토타입 구현 일정 및 예상 개발 비용

프로토타입 구현 일정은 Phase별로 단계적으로 구성되며, 각 Phase의 핵심 마일스톤을 기준으로 진행 상황을 관리한다. Phase 1은 착수 후 약 6개월 이내에 완료를 목표로 하며, 데이터 구축(2개월), 모델 개발 및 검증(2개월), 기본 라우팅 파이프라인 구현 및 연계 테스트(2개월)의 순서로 진행된다. Phase 2는 Phase 1 완료 후 약 4개월 이내 완료를 목표로 하며, 복합 민원 분해 엔진 개발(2개월), Coordinator 에이전트 구현 및 상태 알림 시스템 구축(2개월)으로 구성된다. Phase 3는 Phase 2 완료 후 약 4개월 이내 완료를 목표로 하며, 시스템 최적화(2개월)와 지속 개선 체계 구축 및 전체 시스템 검증(2개월)으로 진행된다. 전체 구현 기간은 착수 후 약 14개월로 계획되며, 각 Phase 완료 시점에서 운영 현황 검토를 통해 일정 조정 여부를 판단한다.

예상 개발 비용은 인력, 인프라, 데이터 구축의 세 가지 주요 항목으로 구성된다. 인력 비용은 AI 엔지니어, 백엔드 개발자, 데이터 엔지니어, 프로젝트 매니저로 구성된 핵심 개발팀의 인건비로, 전체 비용의 가장 큰 부분을 차지한다. 인프라 비용은 모델 학습을 위한 GPU 클라우드 자원, 추론 서버 운영 비용, 데이터 저장소 비용 등으로 구성된다. 데이터 구축 비용은 실제 민

원 데이터 수집, 레이블링, 품질 검증에 소요되는 비용으로, 모델 성능 향상에 직결되는 핵심 투자 항목이다. 정확한 비용 산출을 위해서는 실제 참여 기관의 규모와 요건을 반영한 상세 견적이 필요하며, 본 제안서에서는 개발 항목의 구조만을 기술하고 구체적인 금액은 제시하지 않는다. 비용 효율화를 위해 오픈소스 모델 프레임워크와 클라우드 네이티브 인프라를 최대한 활용하는 전략이 적용된다.

4.4 주요 리스크 및 대응 방안

주요 리스크는 기술적, 데이터, 조직적 세 가지 차원으로 구분하여 관리한다. 기술적 리스크의 첫 번째는 모델 성능 미달 리스크이다. 프로토타입 성능(Accuracy 0.515)이 실제 운영 수준에 미치지 못할 경우, Direct Coverage 목표 달성이 어렵고 Fallback 비율이 높게 유지되어 자동화 효과가 제한될 수 있다. 이에 대한 대응 방안으로 Phase 1에서 학습 데이터를 충분히 확보하고 모델 아키텍처 변경(더 큰 규모의 사전학습 모델 활용 등)을 적극 검토하며, 성능 목표 달성 시점까지 Fallback 경로를 안전망으로 유지한다. 두 번째 기술적 리스크는 기존 시스템 연계 실패이다. 부서별 업무 시스템의 기술 환경이 다양하여 표준 API 연계가 어려운 경우, 라우팅 결과 자동 전달 기능이 구현되지 못할 수 있다. 대응 방안으로는 연계가 어려운 시스템에 대한 대체 연계 방식(파일 기반 전달, 수동 전달 지원 UI 등)을 병행 구현하고, 연계 가능한 시스템을 우선 적용 대상으로 선정하는 단계적 접근을 취한다.

데이터 리스크의 핵심은 실제 민원 데이터 수집의 어려움이다. 개인정보 보호 규정과 데이터 접근 권한 문제로 인해 충분한 양의 실제 민원 데이터를 학습에 활용하기 어려울 경우, 모델 성능 향상이 제한될 수 있다. 대응 방안으로는 개인정보가 완전히 제거된 익명화 민원 데이터를 활용하고, 합성 데이터(synthetic data) 생성 기법을 통해 학습 데이터를 보완하는 전략을 검토한다. 조직적 리스크는 담당 공무원의 AI 시스템 수용성 부족이다. AI 라우팅 결정에 대한 불신이나 기존 업무 방식 변화에 대한 저항이 발생할 경우, 시스템 도입 효과가 실현되지 않을 수 있다. 대응 방안으로는 AI 예측의 투명한 설명, 충분한 교육·훈련 프로그램 제공, 그리고 초

기에는 AI를 의사결정 보조 도구로 포지셔닝하여 점진적으로 자율성을 확대하는 방식을 적용한다.

V. 기대효과

5.1 행정 비용 절감 시뮬레이션

행정 비용 절감 시뮬레이션은 AI-SPOC 도입으로 기대되는 재이첩 감소 및 처리 효율화 효과를 정량적으로 예측하기 위한 프레임워크이다. 시뮬레이션의 핵심 변수는 Direct Coverage 달성률이며, 이를 기반으로 재이첩 발생 건수 감소, 처리 시간 단축, 인력 투입 시간 절감의 연쇄 효과를 추정한다. Direct Coverage 15%가 달성될 경우, 전체 민원의 15%는 오접수 없이 즉시 정확한 담당 부서로 라우팅되어 이 민원들에서의 이첩 발생이 원천 차단된다. 이로 인해 발생 부서와 수신 부서 각각에서의 이첩 관련 행정 작업이 제거되고, 처리 기간이 이첩 없는 수준으로 단축된다. Coordinator 경로의 민원들도 AI의 추가 분석 지원으로 처리 담당자의 판단 시간이 단축되고, 오접수 판단의 정확도가 향상된다. Fallback 경로의 민원도 AI가 제공하는 예측 결과와 신뢰도 정보를 통해 담당자의 의사결정이 지원되어, 완전 수동 처리 대비 일정 수준의 효율화 효과를 기대할 수 있다.

Direct Coverage 35%가 달성될 경우의 시뮬레이션은 더 큰 규모의 행정 비용 절감을 보여준다. 전체 민원의 3분의 1 이상이 오접수 없이 자동 처리되는 상황은, 현재 이첩 처리에 투입되는 행정 인력의 상당 부분을 실질적인 민원 처리 업무로 전환하는 효과를 낳는다. 이는 단순한 비용 절감을 넘어, 행정 서비스의 전반적인 처리 품질과 속도를 향상시키는 구조적 변화로 이어진다. 또한 처리 기간 단축은 법정 처리 기한 준수율 향상으로 나타나며, 이는 민원인 만족도와 행정 신뢰도 제고에 직결된다. 시뮬레이션 결과의 신뢰도는 실제 운영 데이터가 축적됨에 따라 점진적으로 높아지며, Phase 1 운영 후 실측 데이터 기반의 시뮬레이션 갱신이 계획된다.

단, 본 수치는 가정 기반 시뮬레이션 결과이며, 전국 단위 실운영을 위해서는 추가 데이터 확장 및 정책 검증이 필요하다.

5.2 국민 가치

AI-SPOC이 창출하는 국민 가치는 민원 서비스에 대한 접근성 향상, 처리 투명성 제고, 그리고 문제 해결 완전성 보장이라는 세 가지 차원에서 실현된다. 접근성 향상 측면에서, AI-SPOC은 민원인이 행정 분류 체계를 몰라도 자연어로 자신의 문제를 기술하기만 하면 시스템이 적절한 처리 경로를 찾아주는 서비스를 제공한다. 이는 특히 행정 지식이 부족한 일반 시민, 고령층 디지털 취약 계층, 그리고 행정 경험이 없는 외국인 거주자에게 큰 혜택이 된다. 현행 시스템에서 이들은 행정 분류 체계를 이해하지 못해 오접수를 반복하거나, 타인의 도움에 의존해야 하거나, 결국 오프라인 방문 민원으로 회귀하는 불편을 겪지만, AI-SPOC은 이 장벽을 제거한다.

처리 투명성 측면에서, AI-SPOC의 실시간 상태 추적과 자동 알림 기능은 민원인이 자신의 민원이 어디서 어떻게 처리되고 있는지를 언제든지 확인할 수 있게 한다. 재이첩이 발생하더라도 민원인에게 상황이 자동으로 안내되고, 처리 기한이 가까워지면 사전 알림이 전달된다. 복합 민원의 경우, 각 문제별 처리 상태가 통합 화면에 표시되어 어떤 문제가 해결되었고 어떤 문제가 아직 처리 중인지를 한눈에 파악할 수 있다. 이 투명성은 단순한 편의성을 넘어, 행정에 대한 신뢰를 형성하는 핵심 요소이다. 민원인이 행정의 처리 과정을 이해하고 예측할 수 있을 때, 행정 서비스에 대한 만족도와 신뢰도는 구조적으로 향상된다.

문제 해결 완전성 측면에서, AI-SPOC의 복합 민원 자동 분해와 통합 추적 기능은 민원인이 제기한 모든 문제가 적절한 담당 부서로 전달되고 처리되는 것을 보장한다. 현행 시스템에서 복합 민원의 일부가 누락되거나 처리되지 않는 문제가 구조적으로 해소됨으로써, 민원인은 하나의 민원 제출로 자신의 모든 문제가 완전하게 처리되는 경험을 할 수 있다. 이는 '민원을 한 번 제출하면 모든 것이 해결된다'는 신뢰를 구축하며, 동일 문제에 대한 반복 민원 제출을 줄이는 효과도 낳는다.

5.3 행정 가치

AI-SPOC이 창출하는 행정 가치는 처리 효율성 향상, 처리 품질 표준화, 그리고 데이터 기반 행정 혁신의 기반 마련이라는 세 가지 차원에서 나타난다. 처리 효율성 향상의 가장 직접적인 효과는 오접수와 이첩에 투입되던 행정 인력의 실질적 업무 전환이다. AI-SPOC의 Direct 라우팅이 처리하는 민원들에서 발생하던 이첩 관련 행정 작업이 자동화됨으로써, 담당 공무원은 실질적인 민원 해결 업무에 더 많은 시간을 투입할 수 있게 된다. 이는 처리 속도 향상뿐만 아니라, 각 민원에 투입되는 검토 시간의 질적 향상으로도 이어질 수 있다.

처리 품질 표준화 측면에서, AI-SPOC의 알고리즘 기반 라우팅은 동일한 유형의 민원에 대해 일관된 처리 경로를 보장한다. 현행 시스템에서 담당자에 따라 달라지던 이첩 판단의 비밀관성이 해소되며, 민원 처리 결과의 예측 가능성이 높아진다. 이는 행정 서비스의 공정성과 일관성을 향상시키는 동시에, 처리 기준이 알고리즘으로 명문화됨으로써 행정 책임의 소재도 명확해지는 효과를 낳는다. 데이터 기반 행정 혁신의 기반 마련 측면에서, AI-SPOC은 민원 처리 과정의 모든 단계에서 구조화된 데이터를 생성하고 기록한다. 이 데이터는 민원 유형별 발생 패턴, 부서별 처리 부하, 계절적 민원 변동 등 행정 계획 수립에 활용될 수 있는 귀중한 인사이트를 제공한다. 장기적으로 AI-SPOC이 축적하는 민원 데이터는 행정 정책 입안과 자원 배분 최적화를 위한 근거 자료로 활용될 수 있다.

5.4 사회적 가치

AI-SPOC의 사회적 가치는 행정 서비스의 민주화, 디지털 포용성 실현, 그리고 공공 신뢰 회복이라는 세 가지 차원에서 발현된다. 행정 서비스 민주화 측면에서, AI-SPOC은 행정 지식과 디지털 역량의 차이로 인해 발생하는 서비스 접근성 불평등을 해소한다. 현행 시스템에서 교육 수준, 행정 경험, 디지털 활용 능력에 따라 민원 서비스 이용의 효과성이 크게 달라지는 현실은 사회적 불평등의 한 단면이다. AI-SPOC은 이 장벽을 낮춤으로써, 모든 국민이 동등하게 효과적인 행정 서비스를 받을 수 있는 환경을 조성한다. 특히 고령층, 장애인, 저학력자, 외국인 거주자 등 사회적 취약 계층에게 AI-SPOC의 접근성 향상 효과는 더욱 크게 나타난다.

디지털 포용성 실현 측면에서, AI-SPOC의 자연어 인터페이스는 디지털 취약 계층이 복잡한 시스템 조작 없이도 전자민원 서비스를 효과적으로 이용할 수 있게 한다. 현재 디지털 취약 계층은 전자민원 시스템의 복잡성으로 인해 오프라인 방문 민원에 의존하는 경향이 있는데, 이는 이들의 시간과 이동 비용을 증가시킨다. AI-SPOC은 전자민원 서비스의 사용 편의성을 근본적으로 향상시킴으로써, 디지털 취약 계층이 전자민원의 이점을 실질적으로 누릴 수 있도록 지원한다. 공공 신뢰 회복 측면에서, 행정 처리의 투명성 향상과 일관성 확보는 장기적으로 행정 전반에 대한 국민의 신뢰를 회복하는 데 기여한다. 민원이 공정하고 일관되게 처리된다는 신뢰가 형성될 때, 국민과 행정의 관계는 서비스 제공자와 수혜자의 협력적 관계로 발전할 수 있다.

5.5 시스템 확장성 전략

AI-SPOC의 확장성 전략은 수직적 확장과 수평적 확장의 두 방향으로 구성된다. 수직적 확장은 서비스 깊이의 심화를 의미한다. 초기에는 단순 분류와 라우팅에 집중하는 기본 서비스에서 출발하여, 점진적으로 복합 민원 분해, 처리 예측, 선제적 알림, 자동 응답 초안 생성 등의 고도화된 기능을 추가한다. 각 기능 추가는 이전 단계의 운영 데이터를 기반으로 설계되므로, 현실에 맞지 않는 기능 개발의 리스크가 최소화된다. 수직적 확장의 장기적 방향은 AI-SPOC이 민원인과 행정 사이의 지능적 중간자로서 더 많은 역할을 수행하는 것이다. 예를 들어, 민원인에게 예상 처리 기간을 제공하거나, 유사한 선례 민원의 처리 결과를 안내하거나, 민원 제출 단계에서 필요한 첨부 서류를 자동으로 안내하는 기능들이 포함될 수 있다.

수평적 확장은 서비스 적용 범위의 확대를 의미한다. 초기에는 특정 지방자치단체나 특정 민원 유형에 대한 파일럿 운영으로 시작하여, 운영 성과가 검증되면 다른 지자체와 다른 민원 유형으로 확장한다. 이 과정에서 지역별 행정 특수성을 반영한 모델 파인튜닝이 필요하며, 기본 모델 위에 지역별 어댑터를 추가하는 방식으로 확장 비용을 최소화할 수 있다. 중앙정부 민원 서비스로의 확장도 장기 목표로 설정할 수 있으며, 이 경우 지자체 운영에서 축적된 데이터와

노하우가 확장의 기반이 된다. 수평적 확장의 성공은 AI-SPOC 모델과 아키텍처의 재사용성과 적응성에 달려 있으므로, 초기 설계 단계부터 다양한 행정 환경에의 적용을 염두에 둔 범용적 설계 원칙을 적용하는 것이 중요하다.

5.6 성과 측정 지표 (KPI)

```
kim_jinwoong@MacBookPro ~/Downloads/PROVE cat metrics_summary.json
{
  "num_samples": 200,
  "accuracy": 0.515,
  "macro_f1": 0.4579,
  "weighted_f1": 0.4597,
  "top2_accuracy": 0.61,
  "top3_accuracy": 0.71,
  "latency": {
    "avg_ms": 15.0318,
    "p50_ms": 11.9733,
    "p90_ms": 17.8134,
    "max_ms": 394.6164
  },
  "routing_distribution": {
    "fallback": 188,
    "coordinator": 12
  },
  "decision_accuracy": {
    "direct": {
      "N": 0,
      "acc": null
    },
    "coordinator": {
      "N": 12,
      "acc": 0.75
    },
    "fallback": {
      "N": 188,
      "acc": 0.5
    }
  },
  "notes": "All artifacts generated from MODEL_PATH and TEST_PATH; see prove/eval_outputs.jsonl for per-sample logs."
}
```

metrics_summary — 테스트셋 200개 기준 Accuracy 0.515, Macro F1 0.4579, Top-3 accuracy 0.71 등 주요 성능 지표 요약 결과.

AI-SPOC의 성과를 측정하기 위한 핵심 성과 지표(KPI)는 기술 성능, 서비스 품질, 행정 효율, 사용자 만족의 네 가지 범주로 구성된다. 기술 성능 KPI로는 관할 예측 정확도(Accuracy), 복합 민원 분해 정확도, 직접 라우팅 커버리지(Direct Coverage), 추론 지연시간(Latency), 시스템 가용성이 포함된다. 목표 수치는 Phase별로 단계적으로 설정되며, 프로토타입 기준(Accuracy 0.515, metrics_summary.json 참조)에서 각 Phase 완료 시점의 목표 수치로 점진적으로 향상된다. Direct Coverage는 Phase 3 완료 시점에서 정책 목표 범위인 15~35% 달성을 기준으로 평가한다. 추론 지연시간은 현재 프로토타입 수준인 평균 약 10ms를 기준으로, 서비스 환경에

서도 이에 준하는 수준을 유지하는 것을 목표로 한다.

서비스 품질 KPI로는 오접수율 변화, 재이첩 발생률 변화, 평균 민원 처리 기간, 법정 처리 기간 준수율이 포함된다. 이 지표들은 AI-SPOC 도입 전후의 비교를 통해 실질적인 서비스 개선 효과를 측정한다. 행정 효율 KPI로는 이첩 관련 행정 작업 건수 감소율, 담당자 1인당 처리 민원 건수 변화, 복합 민원 처리 완전성(모든 부문이 처리된 비율)이 포함된다. 사용자 만족 KPI로는 민원 처리 결과에 대한 만족도 조사 결과, 전자민원 채널 이용률 변화, 반복 민원 제출 비율 감소, 그리고 디지털 취약 계층의 전자민원 이용률 변화가 포함된다. 이 KPI들은 정기적으로 측정되고 보고되며, 측정 결과에 따라 시스템 개선 우선순위가 재조정된다. KPI 측정 체계 자체의 신뢰성과 일관성을 확보하기 위해, 데이터 수집과 분석 방법론을 사전에 명확하게 정의하고 문서화하는 것이 중요하다.

맺음말

AI-SPOC은 전자민원 행정 체계의 구조적 결함을 해소하기 위한 현실적이고 실현 가능한 기술 기반 혁신 방안이다. 본 제안서는 단순한 개념 제안을 넘어, 실제 프로토타입 개발 결과와 PROVE 파일들에 기록된 실측 데이터를 근거로 시스템의 설계 원칙, 기술 아키텍처, 구현 계획, 그리고 기대 효과를 체계적으로 제시하였다. 프로토타입 단계에서 확인된 모델의 현재 성능 수준은 대규모 상용 서비스를 위한 최종 목표치에 아직 미치지 못하지만, 이는 500개라는 소규모 학습 데이터와 초기 개발 단계의 한계를 반영하는 것이며, 단계적인 데이터 확대와 모델 개선을 통해 목표 성능에 도달할 수 있는 명확한 경로가 설계되어 있다.

AI-SPOC의 근본적인 가치는 기술 그 자체에 있는 것이 아니라, '민원인은 자신의 문제를 자연어로 표현하기만 하면 된다'는 서비스 철학의 실현에 있다. 이 철학은 디지털 전환이 진정한 의미에서 국민 중심 행정으로 이어지기 위한 전제 조건이다. 기술이 사람을 위해 존재해야 한다는 원칙, 그리고 디지털 역량의 차이가 행정 서비스 접근성의 차이로 이어져서는 안 된다는 원칙이 AI-SPOC의 설계 전반을 관통한다.

본 제안서가 제시하는 AI-SPOC 아키텍처는 전자민원 행정의 미래를 향한 하나의 청사진이다. 임계값 기반 3-way 라우팅, HARD Negative 배치를 통한 경계 사례 학습, Whitelist 기반 레이블 품질 관리, 복합 민원 자동 분해, 그리고 실시간 상태 추적 등 본 제안서에서 상세히 기술한 기술 설계 요소들은 AI-SPOC의 실현 가능성을 뒷받침하는 구체적인 근거이다. 이 시스템이 성공적으로 구축되고 운영될 때, 재이첩으로 낭비되던 행정 비용은 실질적인 민원 해결에 투입되고, 디지털 전환의 혜택은 모든 국민이 동등하게 누릴 수 있게 되며, 행정에 대한 국민의 신뢰는 데이터와 투명성에 기반한 견고한 토대 위에 재건될 것이다.

[부록] AI-SPOC 프로토타입 데모 영상

본 제안서의 AI 관할 예측 및 임계값 기반 라우팅 구조를

실제 로컬 모델 환경에서 실행한 시연 영상입니다.

영상 링크:

<https://youtu.be/S-8XOCvpOsc>

(접근 권한: 링크를 통해 누구나 시청 가능)